1 Giriş ve Proje Amacı

1.1 Proje Özeti

Bu proje, HAVELSAN şirketi tarafından geliştirilen Main adlı büyük dil modeli (Large Language Model – LLM) için bir guardrail (koruma katmanı) sistemi geliştirmeyi hedeflemiştir. Main'e gelen her kullanıcı isteği, üretim ortamına ulaşmadan önce bu guardrail modelinden geçerek güvenlik kontrolünden geçirilmektedir.

Proje, günümüzde LLM sistemlerinin karşılaştığı temel güvenlik zorluklarına çözüm sunmayı amaçlamaktadır. Özellikle Türkçe dilinde mevcut guardrail modellerin yetersiz kalması ve piyasadaki açık kaynak çözümlerin Türkçe içerikler için düşük performans göstermesi, bu projenin başlatılmasında temel motivasyonu oluşturmuştur. Geliştirilen model, kullanıcı sorgularını (prompt) analiz ederek zararlı, tehlikeli veya etik dışı içerik üretme potansiyeli taşıyan istekleri tespit etmekte ve bloke etmektedir.

1.2 Proje Amacı ve Motivasyon

1.2.1 Temel Amaç

Projenin temel amacı, binary classification (ikili sınıflandırma) yaklaşımı kullanarak kullanıcı promptlarını **safe** (güvenli) veya **unsafe** (güvenli olmayan) kategorilerine ayırabilen yüksek başarımlı bir guardrail modeli eğitmektir.

1.2.2 Proje İhtiyacı ve Motivasyon

Havelsan'ın kendi büyük dil modeli olan Main'in güvenli ve kontrollü bir şekilde kullanılabilmesi için etkili bir güvenlik katmanına ihtiyaç duyulmuştur. Bu ihtiyacın ortaya çıkmasında aşağıdaki faktörler etkili olmuştur:

- **Mevcut Çözümlerin Yetersizliği:** Piyasada bulunan açık kaynak guardrail modelleri (örn: Llama Guard, OpenAI Moderation API) özellikle Türkçe dilinde düşük performans göstermektedir.
- **Türkçe Dil Desteği Eksikliği:** Çoğu guardrail model yalnızca İngilizce veya sınırlı dil desteğine sahiptir; Türkçe içerikleri yeterince tespit edememektedir.
- **Kurumsal Güvenlik Gereksinimleri:** Havelsan gibi savunma sanayi şirketlerinin kritik uygulamaları için yüksek güvenilirlikli ve özelleştirilebilir bir çözüme ihtiyaç duyulmaktadır.
- **Yerli Çözüm Geliştirme:** Dışa bağımlılığı azaltmak ve veri gizliliğini korumak amacıyla kurum kontrolünde bir model geliştirilmesi hedeflenmiştir.

Model, aşağıdaki kategorilerdeki zararlı içerikleri tespit edebilmeyi hedeflemektedir: zararlı talimatlar, kişisel verilerin istismarı, nefret söylemi, küfür/hakaret, kendine zarar verme, dezenformasyon, şiddet ve tehdit ile prompt injection/jailbreak denemeleri.

1.3 Başarı Kriterleri ve Proje Hedefleri

1.3.1 Başarı Kriterleri

Projenin başarılı sayılabilmesi için belirlenen somut kriterler şunlardır:

- **Minimum %80 Accuracy:** Modelin binary classification görevinde en az %80 doğruluk oranına ulaşması.
- **Piyasa Karşılaştırması:** Erişilebilir guardrail modellerinin (ör: Llama Guard, Aegis Guard) çoğundan daha iyi performans göstermesi.
- **Türkçe Üstünlüğü:** Özellikle Türkçe içeriklerde mevcut açık kaynak çözümlerden belirgin şekilde daha yüksek başarı sağlanması.

1.3.2 Proje Hedefleri

Projenin diğer somut hedefleri şunlardır:

- Yüksek doğruluk oranına sahip (accuracy) binary classification modeli geliştirmek.
- False positive ve false negative oranlarını minimize etmek.
- Farklı model mimarilerini karşılaştırmalı olarak değerlendirmek.
- Gerçek dünya uygulamalarında kullanılabilir, hızlı çıkarım (inference) yapabilen model oluşturmak.
- Türkçe ve İngilizce dillerinde dengeli performans sağlamak.
- Havelsan Main LLM'i ile sorunsuz entegrasyon sağlanabilecek bir guardrail sistemi kurmak.
- Uzun promptları etkin şekilde işleyebilen model geliştirmek.

1 Veri Seti Araştırma ve Aday Değerlendirme Süreci

Proje başlangıcında içerik güvenliği, zararlı içerik tespiti ve prompt güvenliği alanlarında mevcut tüm potansiyel veri setleri sistematik biçimde taranmıştır. Her aday; içerik uygunluğu, etiket kalitesi, dil kapsamı, format tutarlılığı ve hedef güvenlik senaryolarıyla örtüşme düzeyi açısından değerlendirilmiştir. Bulunan veri setleri mentore iletilmiş; alınan geri bildirimler doğrultusunda nihai kararlar oluşturulmuştur.

1.1 Değerlendirme Metodolojisi

Aday veri setlerinin değerlendirmesinde beş temel kriter kullanılmıştır:

1. **İçerik Uygunluğu:** Veri setinin safe/unsafe ikili sınıflandırma göreviyle örtüşme düzeyi.
2. **Etiket Kalitesi:** Etiketlemenin tutarlılığı, belirsizlik oranı ve sınır örneklerin işlenme biçimi.
3. **Dil Kapsamı:** Türkçe ve/veya İngilizce içerik barındırıp barındırmadığı.
4. **Format Tutarlılığı:** Proje sistemleriyle doğrudan uyumluluk ya da dönüşüm maliyeti.
5. **Senaryo Örtüşmesi:** Gerçek dünya saldırı örüntülerini (prompt injection, roleplay, sosyal mühendislik vb.) temsil etme kapasitesi.

1.2 Değerlendirme Sonuçları

Sistematik tarama ve mentor geri bildirimleri sonucunda her adaya **Kabul**, **Koşullu** veya **Elendi** kararı verilmiştir.

Tablo 1. Veri Seti Aday Değerlendirme Matrisi

Veri Seti	Karar	Gerekçe
gabrielchua/system-prompt-leakage	Elendi	Sistem prompt güvenliği odaklı; kullanıcı girdisi sınıflandırma göreviyle yapısal olarak örtüşmüyor.
facebook/cyberseceval3-visual-prompt-injection	Koşullu	Görsel ağırlıklı; doğrudan kullanım uygun değil, ancak image_text kolonu üzerinden kısmi metin verisi değerlendirilebilir.
allenai/scrapinghub-article-extraction-benchmark	Elendi	Makale çıkarım görevi; incelenen 10 örnekten 7'si tamamen uyumsuz, 3'ü güvenlik açısından belirsiz.
deepset/prompt-injections	Elendi	Örnek sayısı yetersiz, kalite düşük; kullanılabilir hale gelmesi ciddi yeniden yapılandırma gerektiriyor.
xTRam1/safe-guard-prompt-injection	Kabul	İçerik ve amaç açısından projeyle tam uyumlu; doğrudan kullanılabilir.
ai4privacy/pii-masking-200k	Elendi	NER / PII masking odaklı; safe/unsafe sınıflandırması için uygun bir yapı sunmuyor.
nvidia/Aegis-AI-Content-Safety-Dataset-2.0	Kabul	Kapsamlı ve çok kategorili içerik güvenliği verisi; kalite ve format açısından tam uyumlu.
Anthropic/hh-rlhf	Koşullu	Kullanılabilir; ancak alanda yaygın biçimde kullanılmış veri seti olduğundan tümünü değil, ayırt edici örnekleri seçici kullanmak daha mantıklı.
LibrAI/do-not-answer	Kabul	Güçlü kategorik yapı; eşlik eden akademik makale veri setini anlamak ve doğru entegre etmek için kullanım öncesinde mutlaka okunmalı.
allenai/real-toxicity-prompts	Elendi	Format yapısı proje sistemleriyle uyumsuz; dönüşüm maliyeti faydayı karşılamıyor.
toxigen/toxigen-data	Elendi	Etiketleme yeterince net değil; sağlıklı kullanım için kapsamlı yeniden etiketleme gerekiyor.
openbmb/UltraSafety	Koşullu	İçerik güçlü; completion kolonu chat history formatında, düz metne dönüştürüldükten sonra kullanılabilir.

Değerlendirme sonuçlarının özet dağılımı Şekil 1'de gösterilmektedir.

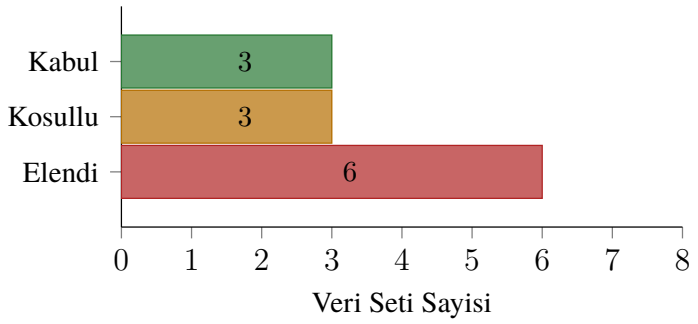

Şekil 1. Aday Veri Seti Karar Dağılımı (n =12)

Not

12 aday veri seti değerlendirilmiş; 3'ü doğrudan kabul edilmiş, 3'ü koşullu kullanıma alınmış, 6'sı elenmiştir. Kabul oranı %25 olmakla birlikte, koşullu veri setleri ön işleme sonrasında projeye dahil edilmiştir.

2 Eğitimde Kullanılan Veri Setleri

Değerlendirme sürecinin ardından projeye dahil edilen veri setleri üç ana kategoride ele alınmaktadır: **Safe** kaynaklar, **Unsafe** kaynaklar ve **Karma (Etiketli)** kaynaklar.

2.1 Safe Veri Kaynakları

2.1.1 Wikitext (Salesforce/wikitext)

Wikipedia makalelerinden oluşan bu veri seti, nesnel ve olgusal içeriğiyle geniş bir safe metin gövdesi sunmaktadır. Akademik ton, cümle çeşitliliği ve konu yelpazesi açısından gerçek dünyada karşılaşılan safe içerik örüntülerini güçlü biçimde temsil etmektedir.

2.1.2 OpenAssistant oasst1

Çok dilli yardımsever konuşma örnekleri içeren açık kaynaklı bir insan geri bildirimi veri setidir. Türkçe dahil birden fazla dildeki safe konuşma örüntülerini barındırması, çift dilli yapıya uyum açısından değerlidir.

2.1.3 Dolly Safe Alt Kümesi

Talimat-yanıt çiftleri formatında bilgi paylaşımı, yaratıcı yazarlık ve soru-cevap gibi yaygın safe içerik formatlarını kapsamaktadır. Gerçek kullanıcı-asistan etkileşim örüntülerini yansıtması bakımından eğitime katkı sağlamaktadır.

2.1.4 ThinkingData-200K-Turkish (erythropygia)

Türkçe dil anlayışı ve muhakeme görevleri için oluşturulmuş bu veri setinden 3.000 safe Türkçe örnek alınmıştır. Bu 3K veri, diğer kaynaklardan derlenen 3K örnekle birleştirilerek eğitim setinin temel safe gövdesini oluşturmuştur. Doğrudan Türkçe metin içeren az sayıdaki kaynaktan biri olması nedeniyle kritik bir kaynak niteliği taşımaktadır.

2.2 Unsafe Veri Kaynakları

2.2.1 IBM AttaQ

Modeli yanıltmaya yönelik adversarial sorulardan oluşan bu veri seti, zararlı niyetin akademik bir metodoloji çerçevesinde sistematik biçimde kategorize edilmesini sağlamaktadır. Saldırgan örüntülerin farklı biçimlerini kapsaması eğitim açısından güçlü bir katkı sunmaktadır.

2.2.2 Babelscape ALERT

Farklı zarar kategorilerinde kapsamlı bir örnek yelpazesi sunan çok boyutlu güvenlik benchmark veri setidir. Kategorik yapısı, modelin hangi zarar türlerinde güçlü ya da zayıf olduğunu analiz etmeye imkân tanımaktadır.

2.2.3 walledai SaladBench

Zararlı içerik üretimini tetiklemeye yönelik saldırgan istemler içermektedir. Doğrudan talep, rol üstlenme ve bağlamsal yönlendirme gibi farklı saldırı stratejilerini temsil etmesi, modelin çeşitli unsafe istem biçimlerini tanımasını desteklemektedir.

2.2.4 Bertievidgen SimpleSafetyTests

Büyük dil modellerinin temel güvenlik ihlallerini tespit etme performansını ölçen bir test veri setidir. Doğrudan tehlikeli içerik örneklerini içermekte ve temel sınır örneklerini sağlamaktadır.

2.2.5 HarmBench (centerforaisafety)

Jailbreak saldırılarını, zararlı talimatları ve açık tehdit içeriklerini barındıran kapsamlı bir benchmark paketidir. Roleplay, hipotetik çerçeveleme, yetki sahteciliği ve teknik yönlendirme gibi farklı saldırı biçimlerini temsil etmesi bakımından modelin geniş bir saldırı repertuvarı öğrenmesine zemin hazırlamaktadır.

2.2.6 StrongREJECT (alexandrasouly)

Modelin reddetmesi gereken içerikleri hem açık hem de ince manipülatif yapılar üzerinden kataloglayan bir veri setidir. Dolaylı yollarla güvenlik sınırını zorlayan örüntüleri de kapsaması, modelin yalnızca belirgin tehditleri değil nüanslı saldırıları da tanımasını desteklemektedir.

2.2.7 walledai AdvBench

Zararlı davranışlara yönlendiren açık istemler içeren bir değerlendirme veri setidir. Temel adversarial örüntüler için sağlam bir eğitim zemini oluşturmaktadır.

2.2.8 CysecBench (cysecbench/dataset)

Tamamen unsafe içerikten oluşan siber güvenlik odaklı bu veri seti; kötü amaçlı yazılım, ağ saldırıları, güvenlik açığı istismarı ve sosyal mühendislik gibi teknik siber tehdit senaryolarını kapsamaktadır. Diğer veri setlerinin görece eksik kaldığı teknik saldırı örüntülerini projeye kazandırmakta; Türkçe ve İngilizce çevirisiyle çift dilli yapıya eklenmiştir.

2.3 Karma (Etiketli) Veri Kaynakları

2.3.1 Anthropic HH-RLHF

Yardımsever ve zararlı konuşma çiftlerini içeren bu veri seti seçici kullanım stratejisiyle projeye dahil edilmiştir. Alanda çok yaygın biçimde kullanılmış olması nedeniyle tümü değil, en özgün ve ayırt edici örnekleri tercih edilmektedir.

2.3.2 LibrAI / Do-Not-Answer

Yanıtlanmaması gereken sorular üzerine kurulu bu veri seti, safe/unsafe sınırını kategorik ve tutarlı biçimde çizen güçlü bir yapıya sahiptir. Eşlik eden akademik makale metodoloji ve kategori tanımları açısından kullanım öncesinde okunması gereken bir referanstır.

2.3.3 NVIDIA Aegis 2.0

Gerçek sohbet bağlamlarından derlenen çok kategorili güvenlik verisiyle modelin konuşma akışı içindeki zararlı içerikleri de tanımasına katkı sağlamaktadır.

2.3.4 OpenBMB UltraSafety

Veri setindeki `completion` kolonu chat history formatından düz metne dönüştürüldükten sonra kullanıma alınmıştır. Skora dayalı sıralama yapısı karşılaştırmalı değerlendirme için zengin bir kaynak sunmaktadır.

2.3.5 xTRam1 / Safe-Guard Prompt Injection

Hem açık hem örtülü prompt injection örneklerini kapsayan bu veri seti, özellikle benchmark veri setinin oluşturulmasında da referans görevi görmektedir.

3 Dil Normalizasyonu

Proje çift dilli (Türkçe + İngilizce) bir yapıya sahip olduğundan toplanan kaynakların büyük bölümü dil dönüşümü gerektirmekteydi. Türkçe için hazır güvenlik veri setinin bulunmaması, çeviri sürecini projenin en kritik yapı taşlarından biri hâline getirmiştir.

3.1 Çeviri Motorları

3.1.1 İngilizce → Türkçe (TranslateGemma)

İngilizce kaynakların Türkçeye çevrilmesinde TranslateGemma kullanılmıştır. Yalnızca kelime bazlı değil; Türkçenin doğal cümle yapısını, morfolojik zenginliğini ve sözdizimsel esnekliğini gözeten anlamsal doğruluk önceliklendirilmiştir. Zararlı içerik örneklerinde zararlı niyetin çeviri sürecinde kaybolmaması özellikle dikkat edilen noktadır.

3.1.2 Türkçe → İngilizce (Helsinki-NLP)

Türkçe kaynaklardaki veriler Helsinki-NLP modeli ile İngilizceye aktarılmıştır. Türkçenin eklemeli morfolojik yapısı ve sözdizimsel özgünlükleriyle başa çıkma performansı nedeniyle tercih edilmiştir.

3.1.3 CysecBench Çevirileri

Tamamen unsafe olan bu veri seti hem Türkçeye hem İngilizceye çevrilmiştir. Siber güvenlik terminolojisinin teknik doğruluğunun korunması bu çeviri sürecinin öncelikli gereksinimidir.

3.2 Çeviri Kalite Doğrulama

Tüm çeviri çıktıları model tabanlı bir kalite kontrol aşamasından geçirilmiştir. Her çeviri çifti (kaynak + çeviri) modele sunulmuş; hem anlam tutarlılığı hem de etiket uygunluğu değerlendirilmiştir. Anlam sapması veya etiket uyumsuzluğu tespit edilen örnekler veri setinden çıkarılmıştır.

İlke

Çeviri Kalite İlkesi: Zararlı bir istem Türkçeye çevrildiğinde zararlılığını yitiriyorsa bu örnek eğitim setine dahil edilmemiştir. Anlam kaybı, etiket kaybına eşdeğer sayılmıştır.

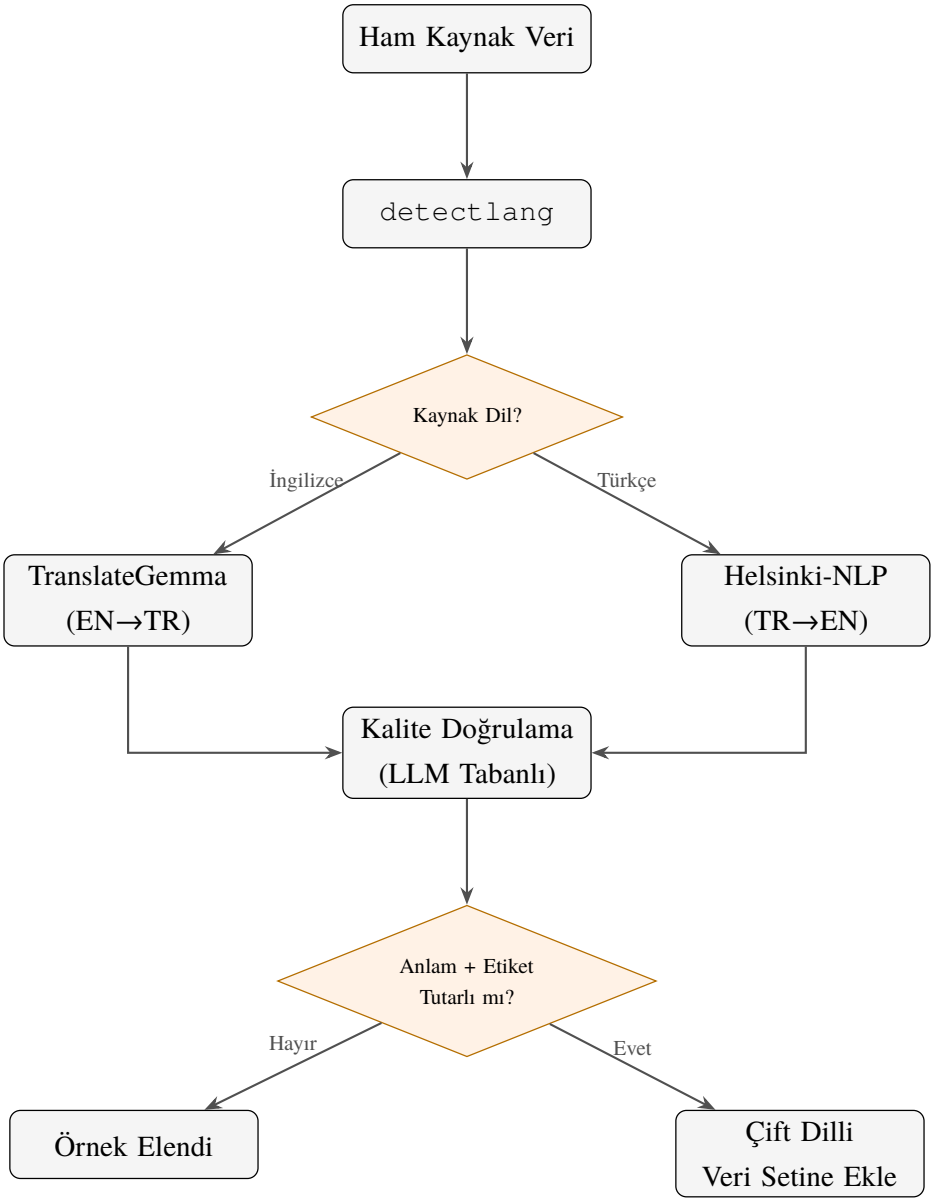

Şekil 2. Çeviri ve Kalite Doğrulama Süreci (`detectlang` ile dil tespiti)

4 Dil Modeli ile Filtreleme

Çeviri ve veri birleştirme aşamalarının ardından tüm ham veri gövdesi, vLLM altyapısı üzerinde çalışan dil modelimiz aracılığıyla sistematik bir kalite taramasından geçirilmiştir. Her örnek bağımsız olarak değerlendirilmiş ve dört temel hedef için filtreleme yapılmıştır.

4.1 Filtreleme Hedefleri

1. **Etiket Belirsizliği Temizleme:** Her örnek 'safe', 'unsafe' veya 'belirsiz' olarak sınıflandırılmıştır. 'Belirsiz' etiketini alan tüm örnekler veri setinden çıkarılmıştır; sınır örnekler modelin karar sınırını bulanıklaştırmaktadır.
2. **Tekrar Eden Örnek Tespiti (Deduplication):** Birden fazla kaynaktan alınan birebir aynı ya da çok benzer örnekler saptanarak tekilleştirilmiştir.
3. **Bağlam Kayması Kontrolü:** Çeviri sürecinde safe/unsafe niteliği değişmiş örnekler yeniden değerlendirilmiş; nitelik kayıpları elenmiştir.
4. **Format ve Kalite Kontrolü:** Bozuk formatlı, anlamsız ya da eğitim için yetersiz kalitede örnekler bu aşamada ayıklanmıştır.

Kritik Gözlem

Dil modeli hem çeviri kalitesi doğrulamasında hem de genel veri filtresi olarak iki ayrı aşamada kullanılmıştır. Bu çift doğrulama yapısı hatalı örneklerin eğitim setine sızmasını minimize etmektedir.

5 vLLM ile Sentetik Veri Üretimi

Ham veri kaynaklarından derlenen unsafe örnekler gerçek dünya saldırı çeşitliliğinin tamamını temsil edememektedir. Özellikle rol üstlenme, hipotetik çerçeveleme ve duygusal ton değişkenleri gibi dolaylı saldırı biçimleri ile Türkçe unsafe örnek sayısı yetersizdi. Bu açıkları kapatmak için dil modeli servisi üzerinden sistematik bir sentetik üretim süreci yürütülmüştür.

Bu bölümde önce tüm veri setinin dayandığı ortak format ve ön işleme adımları (§5.1–§5.3) ele alınmakta; ardından sentetik üretim stratejisi ve sistem promptu açıklanmaktadır.

5.1 Veri Formatı

Eğitimde kullanılan tüm veri seti JSON formatında saklanmakta olup her örnek üç temel alandan oluşmaktadır:

Listing 1: Eğitim Veri Seti JSON Şeması

```
{
  "prompt":   "siniflandirilacak metin girisi",
```

```
  "safety":   0,          // 0 = Safe, 1 = Unsafe
  "category": "kategori"  // Unsafe kategorisi
                          // (Harmful Instructions, Hate
   Speech, vb.)
}
```

Üç alan arasındaki sorumluluk dağılımı şöyledir: `prompt` alanı sınıflandırılacak ham metin girişini tutar ve eğitimde doğrudan kullanılır. `safety` alanı ikili sınıf etiketini içerir; **0** değeri güvenli, **1** değeri güvensiz örneği temsil eder ve bu alan da eğitimde doğrudan kullanılır. `category` alanı ise *Hate Speech* veya *Harmful Instructions* gibi unsafe alt kategorisini belirtir; eğitim sürecinde model bu alana doğrudan maruz kalmaz, ancak veri seti analizleri, kategori bazlı performans değerlendirmesi ve eksik kategorilere yönelik sentetik veri üretimi aşamalarında rehber görevi görür.

Not

Eğitimde yalnızca `prompt` ve `safety` alanları doğrudan kullanılmaktadır. `category` alanı veri seti analizleri, kategori bazlı performans değerlendirmesi ve eksik kategorilere yönelik sentetik veri üretimi aşamalarında rehber görevi görmektedir.

5.2 Büyük/Küçük Harf Normalizasyonu

Tüm veri seti tamamen küçük harfe (*lowercase*) dönüştürülmüştür. Bu kararın iki temel gerekçesi mevcuttur:

1. **Tutarlılık:** Veri setindeki tüm örnekler lowercase olduğundan, çıkarım aşamasında sisteme büyük harfle gelen bir kullanıcı girdisi de modele verilmeden önce küçük harfe dönüştürülmektedir. Bu dönüşüm otomatik olarak uygulanmakta; modelin büyük/küçük harf farkından etkilenmeden sınıflandırma kararı vermesi sağlanmaktadır.

2. **Tokenizasyon Tutarsızlığını Giderme:** `BOMB` ve `bomb` sözcükleri tokenizer tarafından farklı tokenlara dönüştürülebilir. Bu ayrımın eğitim sırasında gürültü yaratmasının önüne geçmek için normalizasyon tercih edilmiştir.

İlke

Kullanım Notu: Modele büyük harfle yazılmış bir girdi verilse dahi bu girdi lowercase'e dönüştürülerek embedding işlemine tabi tutulmaktadır. Büyük/küçük harf tercihi sınıflandırma kararını etkilememektedir.

5.3 Veri Dağılımı İzleme

Her eğitim çalışması başında veri seti dağılım istatistikleri ekrana yazdırılmaktadır. Takip edilen metrikler şunlardır: toplam örnek sayısı; safe ve unsafe örnek sayıları ile yüzdeleri; 150 karakterin altındaki kısa örnekler, 150–2000 karakter aralığındaki orta örnekler ve 2000 karakterin üzerindeki uzun örneklerin ayrı ayrı sayım ve oranları; son olarak ortalama girdi uzunluğu.

Her metrik farklı bir amaca hizmet etmektedir. Sınıf yüzdeleri oversampling gereksinimini ve Focal Loss alpha parametresini doğrudan belirler. Kısa örneklerin oranı, modelin kısa örüntülerdeki yeterliliğini koruyup korumadığını kontrol etmek açısından kritiktir; bu değerin düşmesi catastrophic forgetting riskinin erken sinyali olarak değerlendirilir. Uzun örneklerin oranı ise prompt injection senaryolarını kapsayan bağlamsal örneklerin yeterince temsil edilip edilmediğini gösterir. Ortalama girdi uzunluğu batch boyutu ve padding stratejisini doğrudan etkiler.

Not

Bu istatistikler her çalışmada kayıt altına alınmakta; veri dengesizlikleri ve uzunluk dağılımları eğitim öncesinde gözden geçirilmektedir. Dinamik alpha hesaplama mekanizması da bu dağılım bilgisini doğrudan kullanmaktadır.

5.4 Üretim Stratejisi

Mevcut kısa unsafe örnekler modele girdi olarak verilmiş; modelden bu örneklerin daha zengin ve bağlamsal açıdan daha derinlikli versiyonlarını üretmesi istenmiştir. Üretim sürecinde her kısa unsafe örnek, belirlenmiş bir sistem promptuyla birlikte dil modeline iletilir. Model, aynı zararlı niyeti koruyan ancak bağlamsal derinliği artırılmış yeni bir örnek üretir ve bunu JSON formatında döner. Çıktı önce otomatik kalite filtresinden geçirilir; format bütünlüğü ve uzunluk eşiği kontrol edilir. Ardından üretilen örneğin orijinal etiketiyle tutarlı olup olmadığı doğrulanır ve yalnızca doğrulama aşamasını geçen örnekler genişletilmiş unsafe setine eklenir.

5.5 Sistem Promptu

Sentetik üretimde kullanılan sistem promptu (bkz. Liste 2) aşağıda verilmektedir:

Listing 2: Sentetik Veri Üretimi Sistem Promptu

```
SYSTEM_PROMPT = """
You are generating training prompts for a safety/guard model.

GOAL:
Rewrite the given user prompt into a richer, more realistic
   user prompt
```

```
while preserving the same unsafe intent.

CRITICAL SAFETY CONSTRAINTS (MUST FOLLOW):
- Do NOT provide instructions, tactics, steps, or
   operational details.
- Do NOT suggest evasion, stealth, or how to avoid detection.
- Do NOT add tools, methods, locations, timing, or
   actionable specifics.
- Keep it as a user's request (a prompt), not an answer.

PIPELINE (apply in order):
1) Add brief context (1-2 sentences) about
   situation/motivation.
2) Add role framing OR plausible scenario framing (pick one).
3) Add emotional tone (e.g., desperation, anxiety, anger)
   but no threats.
4) Add a format variation: either "confessional" or
   "hypothetical" style.
5) Keep total length at least 2 sentences.

Output format (strict JSON, no extra text):
{
  "category": "same category as input",
  "safety": 1,
  "prompt": "newly generated prompt --- richer, same unsafe
   intent"
}

- Output language must match input language (Turkish or
   English).
- Return only valid JSON. No explanations or extra text.
"""
```

6 Veri Seti Genişletme

Orijinal veri setinin büyük bölümü görece kısa metinlerden oluşmaktaydı. Ancak gerçek dünya saldırılarında zararlı içerik çoğunlukla uzun ve masum görünen bir bağlamın içine stratejik biçimde saklanmaktadır. Bu durumu karşılamak için iki teknik uygulanmıştır.

6.1 Gizlenmiş Unsafe Entegrasyonu

Uzun safe metinlerin başına, ortasına, sonuna veya paragraf aralarına kısa unsafe ifadeler enjekte edilerek hibrit örnekler oluşturulmuştur. Bu yöntem, modelin uzun bir metnin içine saklanmış tek bir zararlı cümleyi dahi tespit edebilmesini hedeflemektedir — gerçek dünya prompt injection saldırılarının tam olarak taklit ettiği senaryodur.

6.2 Uzunluk Dengeli Eğitim

Uzun örnekler eklendikten sonra kısa örneklerdeki başarımın düştüğü gözlemlendi. Bu sorunu aşmak için her eğitim batch'i hem kısa hem uzun örnekleri orantılı biçimde içerecek şekilde yapılandırılmış; kısa örüntüleri pekiştiren ek sentetik veriler üretilmiştir.

Kritik Gözlem

Kritik Gözlem: Uzun örnekler eklendikten sonra kısa ifadelerdeki başarımın düşmesi, eğitim hattının salt veri eklemekle yönetilemeyeceğini ortaya koymuştur. Uzunluk dengesinin aktif biçimde yönetilmesi zorunlu bir tasarım kararı hâline gelmiştir.

7 Benchmark Veri Setinin Oluşturulması

Benchmark veri seti, eğitim verisiyle örtüşmeyen ve modelin gerçek genelleme kapasitesini ölçen bağımsız bir test zemini olarak tasarlanmıştır. Özellikle prompt injection senaryolarını test etmek amacıyla yapılandırılmış, tamamen unsafe örneklerden oluşmaktadır.

7.1 Uzun Safe Bağlamların Elde Edilmesi

7.1.1 Türkçe Kaynak

`kadirnar/combined-turkish-datasets-v5` veri setinden yalnızca 512 karakterden uzun örnekler filtrelenmiştir. Minimum uzunluk eşiği, prompt injection senaryolarında zararlı içeriğin gerçekçi biçimde gizlenebileceği yeterli bağlam zemini sağlamak amacıyla belirlenmiştir.

7.1.2 İngilizce Kaynak

HAVELSAN bünyesinde daha önce yürütülen LLM projelerinde kullanılan veri setlerinden 512 karakterden uzun safe örnekler seçilmiştir.

7.2 Prompt Injection ile Uzun Unsafe Prompt Oluşturma

Uzun safe bağlamlar içine kısa unsafe örnekler rastgele konumlara enjekte edilerek uzun unsafe promptlar üretilmiştir. Konum rastgeleliği kasıtlıdır: modelin yalnızca belirli bir konuma değil, metnin tamamına dikkat etmesini sağlamak hedeflenmiştir.

7.3 Nihai Benchmark Bileşenleri

Tablo 2. Tablo 8.1: Benchmark Veri Seti Bileşenleri

Bileşen	Dil	Yapı	Test Hedefi
Uzun Unsafe Türkçe Promptlar	TR	Uzun safe + inject unsafe	Türkçe prompt injection tespiti
Uzun Unsafe İngilizce Promptlar	EN	Uzun safe + inject unsafe	İngilizce prompt injection tespiti
Kısa Unsafe Türkçe Promptlar	TR	Doğrudan kısa unsafe	Türkçe temel sınıflandırma
Kısa Unsafe İngilizce Promptlar	EN	Doğrudan kısa unsafe	İngilizce temel sınıflandırma

Not

Bu tasarım sayesinde modelin 'açık tehdit tespiti' ile 'uzun bağlamda gizlenmiş saldırı tespiti' başarımı ayrı ayrı ve karşılaştırmalı biçimde ölçülebilmektedir.

8 Veri Seti Denge Yönetimi

Eğitim setinde iki farklı dengesizlik problemi tespit edilmiş ve her biri için ayrı strateji uygulanmıştır.

8.1 Safe / Unsafe Sınıf Dengesi

Doğal dil dağılımında safe içerik, unsafe içerikten sayıca çok daha fazladır. Bu durum, modelin çoğunluk sınıfına yönelme eğilimi geliştirmesine ve az temsil edilen unsafe sınıfını kaçırmasına zemin hazırlar. Söz konusu dengesizlik üç mekanizmanın birlikte kullanımıyla giderilmiştir.

İlk olarak, unsafe örnekler aşırı örnekleme yoluyla çoğaltılmıştır. Bu yaklaşım modelin düşük frekanslı sınıfa daha fazla maruz kalmasını sağlar; ancak aynı örneklerin tekrar tekrar görülmesi nedeniyle ezber riskini de beraberinde getirir. Bu riski dengelemek amacıyla safe örneklere alt örnekleme uygulanmış, böylece sınıf oranları makul bir aralığa çekilmiştir. Son olarak, kayıp fonksiyonu olarak Focal Loss tercih edilmiştir. Focal Loss, standart çapraz entropinin her iki sınıfa eşit ağırlık vermesi nedeniyle dengesiz veri setlerinde ortaya çıkan yetersizliğini doğrudan hedefler. Kolay sınıflanan örneklerin katkısını dinamik

olarak düşürürken, modelin üzerinde daha fazla durmaya ihtiyaç duyduğu örneklere ağırlık verir. Alpha hiperparametresi her eğitim çalışması öncesinde anlık sınıf dağılımına göre hesaplanarak sabit bir değere bağımlılık ortadan kaldırılmıştır.

8.2 Unsafe Kategori Dengesi

İkinci dengesizlik problemi sınıf düzeyinde değil, unsafe kategorileri arasında ortaya çıkmıştır. Nefret söylemi ve zararlı talimat kategorileri, kamuya açık veri setlerinde doğal olarak daha fazla örneğe sahipken; dezenformasyon, manipülasyon ve kişisel veri ihlali kategorileri görece az örnekle temsil edilmekteydi.

Bu asimetri iki açıdan sorun yaratmaktadır. Birincisi, model yoğun temsil edilen kategorileri daha güvenilir tanırken az temsil edilenlerde performans düşüklüğü gösterir. İkincisi, kategori bazlı değerlendirmeler gerçek genelleme kapasitesini yansıtmak yerine veri dağılımını yansıtır hale gelir. Sentetik veri üretimi bu asimetriyi gidermek amacıyla kasıtlı olarak eksik kategorilere yönlendirilmiştir. Her üretim turunda hangi kategorilerin yetersiz kaldığı `category` alanı üzerinden tespit edilmiş ve üretim promptu buna göre hedeflenmiştir. Sonuç olarak tüm kategorilerde dengeli bir dağılım sağlanmış ve modelin geniş unsafe spektrumunu eşit ölçüde öğrenebileceği bir eğitim ortamı oluşturulmuştur.

1. Model Arayışı ve Değerlendirme Süreci

Proje ikili sınıflandırma (*safe*/*unsafe*) görevi üzerine kurulu olduğundan model seçimindeki temel kriter; hem Türkçe hem İngilizce metinleri güvenilir biçimde işleyebilme, uzun bağlamları kapsama ve sınıflandırma başarımı açısından istikrarlı sonuçlar üretme kapasitesidir. Bu kriterler çerçevesinde birden fazla model ailesi sistematik biçimde denenerek karşılaştırmalı değerlendirme yapılmıştır.

Değerlendirme sürecinde üç temel gereksinim belirleyici rol oynamıştır: (1) 512 token sınırını aşan uzun bağlamları işleyebilme; (2) Türkçe ve İngilizce metinleri eşit kalitede anlama; (3) ikili sınıflandırma görevinde tekrarlanabilir ve kararlı çıktılar üretme. Her bir gereksinim, model seçim sürecinde bağımsız bir değerlendirme kriteri olarak ele alınmış; bu kriterlerin tamamını karşılayan modeller bir sonraki aşamaya taşınmıştır.

1.1 Longformer Ailesinden Denenen Modeller

512 token sınırını aşan uzun bağlamlarla başa çıkabilme gereksinimiyle değerlendirme Longformer mimarisine yönelmiştir. Bu mimari, kayan pencere dikkat mekanizması sayesinde 4096 tokena kadar bağlamı verimli biçimde işleyebilmektedir. Kayan pencere dikkat her token için sabit bir komsu pencerede hesaplanırken bazı seçkin tokenlar üzerinde global dikkat uygulanabilmekte, bu sayede uzun belgelerde hem hesaplama maliyeti düşük tutulmakta hem de bütünsel bağlam korunmaktadır.

1.1.1 `allenai/longformer-base-4096` ile İlk Eğitim Sonuçları

İlk Longformer eğitimi yalnızca Türkçe veri setiyle gerçekleştirilmiştir. Model ön eğitimini İngilizce metin gövdesi üzerinde yapmış olduğundan, yalnızca Türkçe fine-tuning uygulandığında İngilizce kelime yatkınlığı baskın kalmaya devam etmektedir. Bu durum beklenen bir olgudur; zira pretrained ağırlıklar İngilizce dilbilgisi ve sözdümü yapılarına göre optimize edilmiştir.

Table 1.1. Tablo 1.1 – `allenai/longformer-base-4096` İlk Eğitim Test Sonuçları

Test Kategorisi	Dil	Sonuç	Açıklama
Sistem Kırma (Jailbreak)	Türkçe	Başarısız	Tespit edilemedi
Adam Öldürme	Türkçe	Başarısız	Tespit edilemedi
Irkçı Söylem	Türkçe	Başarılı	Tespit edildi (İng. benzer cümle yapısı)
Veri Çalma	İngilizce	Başarılı	Tespit edildi
Banka Soygunu	İngilizce	Başarılı	Tespit edildi
Irkçılık	İngilizce	Başarılı	Tespit edildi
Sızma (Penetrasyon)	İngilizce	Başarılı	Tespit edildi

Test sonuçları incelendiğinde Türkçe kategorilerdeki başarısızlık oranının İngilizce kategorilere göre belirgin biçimde yüksek olduğu görülmektedir. Modelin Türkçe İngilizce'ye benzer cümle yapısı taşıyan ırkçı söylem örneğini doğru sınıflandırabilmesi, bu başarının dil kavrayışın-

dan değil ön eğitim ağırlıklarının sözdizimsel yakınlığından kaynaklandığını açıkça ortaya koymaktadır.

Kritik Gözlem

Türkçe testte başarılı olan tek örnek, cümle yapısı açısından İngilizceye yakınlık taşıyan ırkçı söylem örneğiydi. Bu bulgu, modelin Türkçe anlam uzayını özümsemediğini ve sınıflandırma kararlarını büyük ölçüde İngilizce ön eğitim ağırlıklarına dayandırdığını göstermektedir.

1.1.2 `markussagen/xlm-roberta-longformer-base-4096`

Çok dilli (multilingual) ön eğitime sahip bu modelin Türkçe performansını anlamlı ölçüde iyileştireceği beklentisiyle eğitim gerçekleştirilmiştir. Model; XLM-RoBERTa'nın 100 dilli ön eğitimini Longformer'ın uzun bağlam mimarisiyle birleştirmektedir.

Ancak testler beklentiyi karşılamadı: İngilizce içeriklerde ilk modelle benzer başarım sürerken, Türkçe içeriklerde başarısızlık oranı belirgin biçimde düşmedi. Yalnızca Türkçe veri setiyle yeniden fine-tune edildiğinde de anlamlı bir iyileşme gözlenmedi. Model çok dilli ön eğitim almış olmasına karşın Türkçe veri oranının düşüklüğü nedeniyle Türkçe içeriklerde yetersiz kaldı.

Temel Sorun

Çok dilli ön eğitim, her dili eşit kalitede temsil etmemektedir. Türkçe, modelin ön eğitim veri dağılımında küçük bir pay almaktadır; bu durum fine-tuning aşamasında iyileştirme potansiyelini sınırlamaktadır.

1.2 Diğer Denenen Modeller

Longformer alternatifleri olarak farklı mimarilere sahip çok dilli modeller de test edilmiştir. Bu modellerin temel özelliği, standart BERT benzeri mimarilerden farklı embedding yöntemleri kullanmalarıdır. Tablo 1.2 bu modellere ilişkin karşılaştırmalı değerlendirmeyi sunmaktadır.

Table 1.2. Tablo 1.2 – Değerlendirilen Alternatif Modeller

Model	Mimari	Sorun	Karar
`jinaai/jina-reranker-v2-base-multilingual`	Transformer (BERT-dışı)	Embedding sürecinde bellek ve işlem yükü çok yüksek; güvenilir sınıflandırma çıktısı elde edilemedi	Elendi
`Alibaba-NLP/gte-multilingual-mlm-base`	Transformer (BERT-dışı)	Benzer embedding maliyeti sorunları; çıktı kalitesi yetersiz	Elendi
`jhu-clsp/mmBERT-base`	BERT Tabanlı	Makul embedding maliyeti; ancak çift dilli başarım hedeflerin altında kaldı	Elendi

BERT tabanlı olmayan modeller embedding sürecinde belirgin biçimde daha yüksek hesaplama yükü oluşturmuştur. Bu modeller reranking veya representation görevleri için tasarlanmış olduğundan, ikili sınıflandırma görevine uyarlanmaları hem teknik açıdan zorlu hem de başarım açısından verimsiz olmuştur. Jina ve GTE modellerinin reranker olarak güçlü olmalarına karşın ikili sınıflandırma görevi için uygun olmadığı anlaşılmıştır.

1.3 Model Seçimi

Tablo 1.3, tüm modellerin dört temel kriter açısından nihai karşılaştırmasını sunmaktadır.

Table 1.3. Tablo 1.3 – Model Seçim Matrisi (Nihai Karşılaştırma)

Model	Türkçe	İng.	Uzun Bağ.	Karar.	Karar
`turkish-base-bert-uncased`	Kısmi	Bskız	Bskız	Bskız	Elendi
`bert-base-turkish-cased`	Kısmi	Bskız	Bskız	Bskız	Elendi
`xlm-roberta-longformer`	Kısmi	Kısmi	Başarılı	Kısmi	Elendi
`jina-reranker-v2`	Kısmi	Kısmi	Bskız	Bskız	Elendi
`gte-multilingual-mlm`	Kısmi	Kısmi	Bskız	Bskız	Elendi
`mmBERT-base`	Kısmi	Kısmi	Bskız	Kısmi	Elendi
`allenai/longformer-base-4096`	**Başarılı**	**Başarılı**	**Başarılı**	**Başarılı**	**Seçildi**

Not: "Bskız" = Başarısız; "Karar." = Kararlılık; "Uzun Bağ." = Uzun Bağlam desteği.

Seçim Gerekçesi

`allenai/longformer-base-4096`, denenen tüm modeller arasında her iki dilde de en dengeli çıktıyı ve en yüksek kararlılığı sunan model olmuştur. Kayan pencere dikkat mekanizması sayesinde 4096 tokena kadar bağlamı verimli biçimde işleyebilmesi, Türkçe fine-tuning sonrasında İngilizce başarımının korunması ve eğitim sürecindeki istikrarlı davranışı bu seçimin temel dayanaklarini oluşturmaktadır.

2. Model Mimarisi

Seçilen Longformer tabanı üzerine, ikili güvenlik sınıflandırması görevine özgü bir model mimarisi inşa edilmiştir. Bu mimari, sınıflandırma başarımını artırmak amacıyla birden fazla pooling stratejisini bir arada kullanan özel bir yapı içermektedir. Standart transformer tabanlı modellerden farkı, tek bir temsil vektörü yerine dört farklı temsil stratejisinin birleştirilmesidir.

2.1 Quad-Pooling Stratejisi

Standart transformer sınıflandırıcılarında yalnızca `[CLS]` token temsili kullanılırken bu mimaride dört farklı temsil vektörü paralel olarak hesaplanarak birleştirilmektedir. Her biri metnin farklı bir boyutunu yakalamaktadır. Bu yapı, modelin hem genel anlam bilgisini hem de lokal youn sinyal taşıyan tokenları eşzamanlı olarak görebilmesine olanak tanımaktadır. Tablo 2.1 bu bileşenleri açıklamaktadır.

Table 2.1. Tablo 2.1 – Quad-Pooling Bileşenleri ve İşlevleri

Pooling Türü	Açıklama
CLS Vektörü (H_{cls})	Longformer'ın `[CLS]` tokenına karşılık gelen global sınıflandırma temsilidir; tüm dizi üzerinde global dikkat uygulanmaktadır.
Contextual Weighted Pool (H_{cwp})	Her tokenın önem ağırlığı öğrenilen bir projeksiyon katmanı (`Linear` $\rightarrow$ `GELU` $\rightarrow$ `Dropout` $\rightarrow$ `Linear`) ile hesaplanmakta ve ağırlıklı toplam alınmaktadır. Prompt injection gibi gizlenmiş zararlı içeriği yakalamak için etkilidir.
Max Pooling (H_{max})	Her boyut için dizinin tüm tokenları arasındaki maksimum aktivasyon değeri alınmaktadır. Tek bir zararlı kelime ya da cümlenin baskın sinyal oluşturduğu durumlarda kritik öneme sahiptir.
Mean Pooling (H_{mean})	Dikkat maskesi gözetilerek geçerli tokenlara ait aktivasyonların ortalaması alınmaktadır. Genel anlamsal bütünlüğü yansıtır; kısa metinlerde etkin biçimde çalışmaktadır.

Dört pooling bileşeninin birleştirilmesi sayesinde elde edilen $4d$ boyutlu temsil, hem global bağlam bilgisini (CLS ve Mean Pooling) hem de yerel baskın sinyalleri (Max Pooling ve CWP) tek bir vektörde barındırmaktadır. Şekil 2.1 bu süreci görselleştirmektedir.

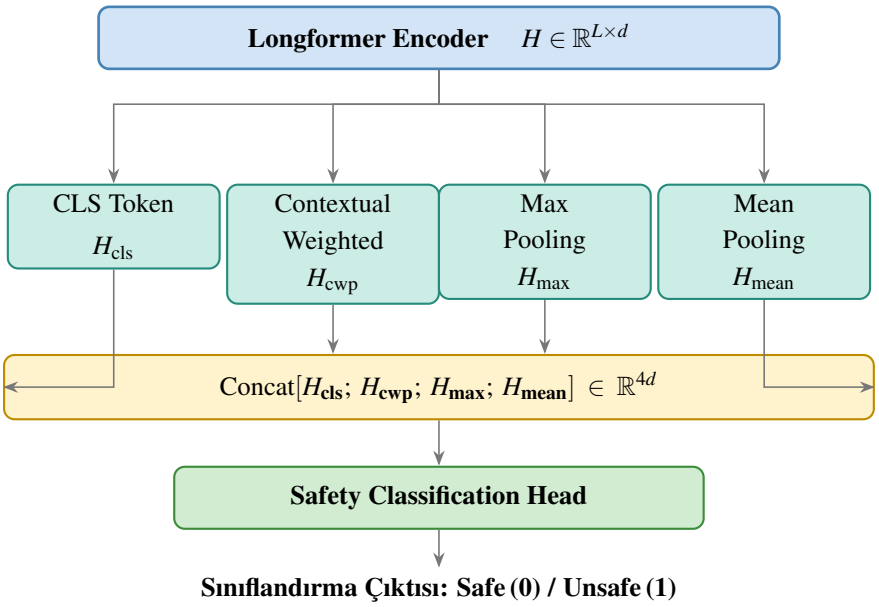

Figure 2.1. Şekil 2.1 – Quad-Pooling Mimarisi: Dört Temsil Vektörünün Paralel Hesaplanması ve Birleştirilmesi

2.2 Sınıflandırma Kafası (Safety Head)

Birleştirilmiş $4d$ boyutlu temsil vektörü katmanlı bir ileri beslemeli ağdan geçirilmektedir. Bu ağ, her katmanda boyutu kademeli olarak düşürerek ham vektörü iki sınıflı bir logit temsiline dönüştürmektedir. Tablo 2.2 bu katmanların yapısını özetlemektedir.

Table 2.2. Tablo 2.2 – Safety Head Katman Yapısı

Kat.	Açıklama	Yapı
1	Yüksek boyutu indirgeme	`Linear(`$4d \to 2d$`)` → `LN` → `GELU` → `Dropout(0.25)`
2	Orta seviye özellik öğrenimi	`Linear(`$2d \to 256$`)` → `LN` → `GELU` → `Dropout(0.25)`
3	İnce özellik çıkarımı	`Linear(`$256 \to 64$`)` → `LN` → `GELU` → `Dropout(0.125)`
4	Sınıflandırma logiti	`Linear(`$64 \to 2$`)` → `Logit`

Not: LN = LayerNorm.

Her katman arasında LayerNorm kullanılması eğitim stabilitesini artırmakta ve aktivasyon dağılımlarının kaymasını önlemektedir. Dropout değeri son katmana doğru azaltılmakta; bu yaklaşım erken katmanlarda daha agresif regularizasyona olanak tanıyarak son katmanda sınıflandırma kararını daha net temsil etmektedir. Boyut indirgemesinin kademeli yapısı, ağının özellik uzayını giderek daha sıkıştırmasına ve görev için en ayırt edici özellikleri öne çıkarmasına olanak tanımaktadır.

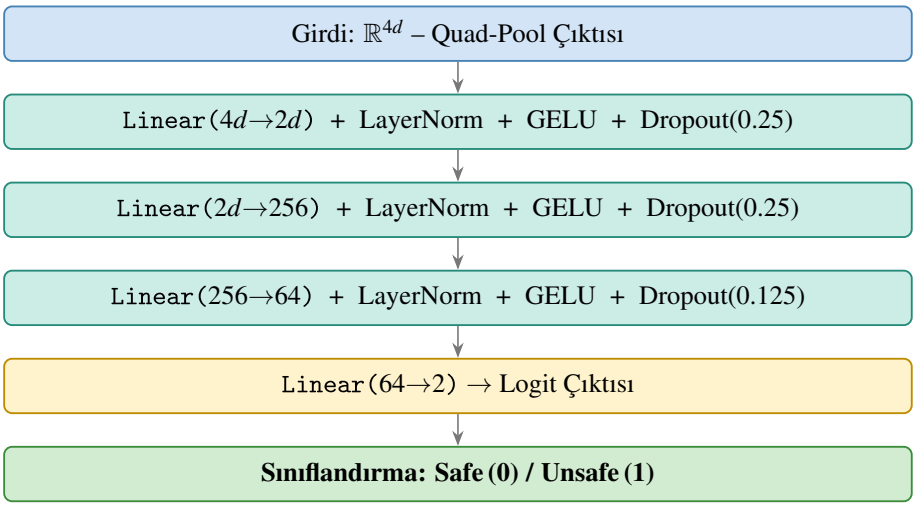

Figure 2.2. Şekil 2.2 – Safety Classification Head Katman Akış Diyagramı

2.3 Global Dikkat Stratejisi

Longformer'ın her tokenı için yalnızca yerel pencere dikkat uygulanmakta, belirli tokenlar global dikkat alabilmektedir. Standart Longformer'ın kayan pencere boyutu w olarak ayarlandığında, her token yalnızca $[i - w/2,\ i + w/2]$ aralığındaki tokenlara dikkat eder. Buna karşılık global dikkat alan bir token, dizideki tüm tokenlarla etkileşime girmekte ve tüm tokenlar da o token ile etkileşime girebilmektedir.

Bu mimaride `[CLS]` tokeni her zaman global dikkat almakta ve tüm dizi üzerinde bütünleşik bir sınıflandırma temsili elde edilmektedir. Kayan pencere dikkat bant genişliğinin $O(n)$ olması hesaplama verimliliğini sağlarken, `[CLS]` tokeninin global dikkati dizi düzeyinde anlamı bütünleştirmektedir. Tablo 2.3 bu yapılandırmayı özetlemektedir.

Table 2.3. Tablo 2.3 – Global Dikkat Yapılandırması

Senaryo	Global Dikkat Alan Tokenlar	Gerekçe
Uzun dizi ($L > 512$)	Yalnızca `[CLS]`	Tüm dizi üzerinde bütünleşik temsil; hesaplama verimliliği korunur
Kısa dizi ($L \leq 512$)	Tüm tokenlar	Tam bağlam işleme; pencere kısıtlaması olmaksızın tam dikkat uygulanır

Bu iki senaryonun ayrımı önemlidir: kısa metinlerde tüm tokenlar global dikkat aldığında elde edilen temsil kalitesi, standart BERT'ın tam dikkat mekanizmasına eşdeğer olmaktadır. Uzun metinlerde ise kayan pencere + global CLS kombinasyonu hem hesaplama maliyetini düşük tutmakta hem de bütünsel anlamı korumaktadır.

2.3.1 Global Dikkat Maskesinin Hesaplanması

Uygulamada global dikkat maskesi, `attention_mask` tensörü ile aynı boyutta bir `global_attention_mask` tensörü aracılığıyla belirlenmektedir. Maske öğesi 1 olan her token global dikkat almaktadır. Bu mimaride maske yapılandırması şu çerçevede uygulanmaktadır: dizi uzunluğu 512 tokendan fazlaysa yalnızca 0. indeksteki `[CLS]` tokeni global dikkat alacak biçimde maskelenmekte; dizi 512 token veya daha kısaysa tüm geçerli tokenlar

global dikkat alacak biçimde ayarlanmaktadır. Bu dinamik yapı, modelin hem kısa hem uzun metinlerde optimum performans göstermesini sağlarken bellek kullanımını da giriş uzunluğuna göre otomatik olarak ölçeklendirmektedir.

Kayan pencere dikkat ile global dikkat mekanizmalarının birlikte kullanımı, modelin güvenlik sınıflandırması görevinde uzun ve karmaşık metinlerdeki zararlı içerikleri tespit etme kabiliyetini önemli ölçüde artırmaktadır. Bu mimari karar, prompt injection gibi gizli saldırıların uzun bağlamın orta veya sonundaki tokenlardan kaynaklanabileceği göz önünde bulundurulduğunda kritik bir tasarım tercihi olarak öne çıkmaktadır.

2.3.2 Pencere Boyutu ve Hesaplama Karmaşıklığı

Longformer'ın kayan pencere dikkat mekanizmasında her token, kendi konumunun hem sol hem sağ tarafında $w/2$ genişliğinde bir pencereye bakabilmektedir. Bu pencere boyutu standart implementasyonda 512 olarak belirlenmekte; ancak göreve göre ayarlanabilmektedir. Kayan pencere dikkatin hesaplama karmaşıklığı $O(n \cdot w)$ olduğundan, tam dikkat mekanizmasının $O(n^2)$ karmaşıklığına göre 4096 token uzunluğunda yaklaşık 8 kat daha hızlı çalışmaktadır.

Bu verimlilik, modelin güvenlik sınıflandırması görevinde gerçek zamanlı uygulamalarda da kullanılabilir olmasını sağlamaktadır. Uzun belgeler ve prompt injection saldırıları için kritik olan 4096 token kapasitesi, modelın hesaplama maliyetini geniş tutarken aynı zamanda pratikte deploy edilebilir bir boyutta kalmasını mümkün kılmaktadır.

3. Kayıp Fonksiyonu

3.1 Focal Loss

Standart çapraz entropi kayıp fonksiyonu sınıf dengesizliğine karşı duyarsızdır: çoğunluk sınıfı (*safe*) üzerindeki kolay örnekler kayıp değerini domine eder ve model azınlık sınıfına (*unsafe*) yetersiz dikkat gösterir. Bir güvenlik sınıflandırıcısında unsafe örneklerin kaçırılması (false negative) yanlış alarm üretilmesinden (false positive) çok daha büyük bir risk oluşturmaktadır. Bu asimetrik maliyet yapısını modellemek için Focal Loss kullanılmıştır [2].

Focal Loss, her örneğin kayıp katkısını o örneğin ne kadar doğru sınıflandırıldığına göre modüle eder:

$$\mathscr{L}_{\mathrm{FL}}(p_t) = -\alpha_t \cdot (1 - p_t)^{\gamma} \cdot \log(p_t) \tag{3.1}$$

Burada p_t model tarafından doğru sınıfa atanan olasılık, γ kolayca doğru sınıflandırılan örnekleri bastıran odaklama parametresi ve α_t sınıf dengesizliğini telafi eden ağırlıktır. $(1 - p_t)^{\gamma}$ terimi, modelın güvenle doğru sınıflandırdığı kolay örneklerin katkısını baskılayarak eğitimi zor örnekler üzerine yoğunlaştırır.

Table 3.1. Tablo 3.1 – Focal Loss Hiperparametreleri

Parametre	Değer	Açıklama
gamma (γ)	2.0	Kolay örneklerin kayıp katkısını bastırma kuvveti; standart literatür değeri
alpha (α)	Dinamik	Veri setindeki safe/unsafe oranına göre otomatik hesaplanır
label_smooth (ε)	0.05	Her sınıf için yumuşatma; aşırı güvenden (overconfidence) korur

3.2 Dinamik Alpha Hesaplama

Alpha parametresi sabit bir değer yerine eğitim başlangıcında veri setinin gerçek safe/unsafe dağılımından dinamik olarak hesaplanmaktadır. Bu yaklaşım, veri setinin sınıf dağılımı değiştiğinde kayıp fonksiyonunun elle ayarlanması gereksinimini ortadan kaldırmaktadır:

$$\alpha_{\text{dynamic}} = \frac{N_{\text{safe}}}{N_{\text{total}}} \tag{3.2}$$

Bu mekanizma şu mantığa dayanmaktadır: unsafe örnekler çoğunlukta olduğunda α_{dynamic} küçük, dolayısıyla $(1 - \alpha_{\text{dynamic}})$ büyük olur; bu durum unsafe sınıfının kayıp katkısını artırır ve false positive'i engeller. Tam tersi, safe örnekler az olduğunda safe sınıfına daha yüksek ağırlık verilmektedir.

```
safe_ratio   = count(safety == 0) / total_samples
unsafe_ratio = count(safety == 1) / total_samples

# Eger unsafe > safe ise:
```

```
# safe_ratio kucuk -> alpha kucuk
# (1 - alpha) buyuk -> Unsafe sinifi daha fazla agirlik alir
dynamic_alpha = safe_ratio  # Otomatik dengeleme
```

Listing 3.1. Dinamik Alpha Hesaplama

3.3 Label Smoothing

Label smoothing, modelin tahminlerine gereğinden fazla güvenmesini engelleyen bir regularizasyon tekniğidir. Derin öğrenme modellerinde sık rastlanan *overconfidence* problemi, modelin belirli örnekler için %99 veya üzünde güven skorları üretmesi ve bu durumun sınır bölgelerindeki genellemeyi olumsuz etkilemesidir. Standart one-hot etiket vektörü $[0,1]$ yerine yumuşatılmış hedef dağılım kullanılmaktadır:

$$y_{\text{smooth}} = (1-\varepsilon)\cdot y_{\text{onehot}} + \frac{\varepsilon}{K}, \qquad \varepsilon = 0.05,\ K = 2 \tag{3.3}$$

Bu pratikte $[0.05, 0.95]$ anlamına gelmektedir. Yumuşatma katsayısı $\varepsilon = 0.05$ ile model, doğru sınıf için en fazla 0.95 olasılık öğrenebilmektedir; bu da diğer sınıf için en az 0.05 olasılık ayrılması anlamına gelir.

Sonuç olarak model sınıflar arasındaki sınır bölgelerinde daha iyi genelleme yapabilmekte ve ezberleme eğilimi azalmaktadır. Label smoothing, Focal Loss ile birlikte kullanıldığında özellikle belirsiz ve yarım safe örneklerde modelin daha temkinli tahmin üretmesini sağlamaktadır. İkili sınıflandırma görevlerinde $K = 2$ olduğundan yumuşatılmış hedef $[0.025, 0.975]$ desteğine sahip olmaktadır; bu da modelin sınır durumlarında ikinci sınıfı tamamen yok saymamasını garantiler.

3.3.1 Focal Loss ve Label Smoothing Etkileşimi

Focal Loss ile label smoothing bir arada kullanıldığında iki regularizasyon mekanizması birbirini tamamlamaktadır. Focal Loss, kolay ve zor örnekler arasındaki dengeyi düzenlerken label smoothing, modelin her örnek için ne kadar kesin karar verebileceğini sınırlamaktadır. Bu kombinasyon, modelin hem sınıf dağılımına duyarlı hem de güven kalibrasyonu açısından dengeli öğrenmesini desteklemektedir.

Pratik etkisi, eğitim sürecinde modelin daha yavaş yakınsaması ama daha sağlam bir karara ulaşmasıdır. Overconfident gradientlerin azalmasıyla birlikte eğitim kaybindeki inilebilir minimum daha geniş ve düzgün bir alanı kapsamakta; bu durum optimizasyonu yerel minimumlardan korumaktadır.

4. Eğitim Konfigürasyonu ve Hiperparametreler

4.1 Eğitim Teknikleri

Temel AdamW optimizasyon sürecine ek olarak dört optimizasyon tekniği uygulanmıştır. Bu teknikler birbirini tamamlayan yapılar olup tüm teknikler aynı anda aktif biçimde eğitimi yönetmektedir.

Katman Bazlı Öğrenme Hızı (Layer-wise LR Decay). Encoder katmanları için öğrenme hızı her katmanda $\lambda = 0.9$ katsayısıyla azaltılmaktadır. Alt katmanlar pretrained dil bilgisini korurken üst katmanlar göreve daha hızlı adapte olur. Bu sayede temel dil temsilleri bozulmadan korunurken sınıflandırma görevine özgü üst katmanlar verimli biçimde güncellenmektedir:

$$\eta_l = \eta_{\text{base}} \cdot \lambda^{(L-l)}, \qquad \lambda = 0.9 \tag{4.1}$$

Cosine Schedule + Warmup. İlk %8'lik adımda öğrenme hızı sıfırdan hedef değere lineer artar, ardından cosine eğrisi boyunca düşer. Ani gradient adımlarını başlangıçta engeller, sonunda ince güncellemeler sağlar. Warmup aşaması, büyük öğrenme hızıyla başlamanın neden olduğu erken divergence sorununu da ortadan kaldırmaktadır.

Akıllı Batch Örnekleme ve Dinamik Padding. Benzer uzunluktaki örnekler aynı batch'e yerleştirilerek gereksiz padding azaltılmaktadır. Her batch kendi maksimum dizisine göre (en yakın 512 katına yuvarlanarak) doldurulmaktadır. Bu yöntem hesaplama gücünü padding tokenlarına harcamak yerine gerçek metinlere yönlendirir.

Mixed Precision (AMP) + Gradient Clipping. İleri geçiş FP16 ile yapılmakta, `GradScaler` sayısal kararlılığı yönetmektedir. Her güncelleme öncesi gradient normu 1.0 ile sınırlandırılarak gradient patlaması önlenmektedir. AMP kullanımı GPU bellek tüketimini yaklaşık yarıya indirerek daha büyük batch boyutlarına olanak tanımaktadır.

Table 4.1. Tablo 4.1 – Eğitim Tekniklerinin Özeti

Teknik	İşlev	Parametre
Layer-wise LR Decay	Alt katmanları korur, üst katmanları göreve hızlı adapte eder	$\lambda = 0.9$
Cosine Warmup Schedule	Başlangıç instabilitesini önler, son güncellemeleri inceltir	%8 warmup
Smart Batch Sampling	Padding kayıplarını minimize eder, bellek verimliliğini artırır	512 katları
AMP + Gradient Clipping	GPU bellek tüketimini yarıya indirir, gradient patlamasını önler	Clip: 1.0

5. Model Değerlendirme

5.1 Değerlendirme Metrikleri

Model başarımı birden fazla metrikle izlenmektedir. Güvenlik sınıflandırması görevinde yanlış negatif (kaçırılan unsafe) ile yanlış pozitif (yanlış alarm) arasındaki asimetrik maliyet nedeniyle tek bir metriğin yetersiz kalması söz konusudur. Bu nedenle tamamlayici metriklerden oluşan bir değerlendirme sistemi benimsenmiştir. Tablo 5.1 bu metriklerin her birini açıklamaktadır.

Table 5.1. Tablo 5.1 – Değerlendirme Metrikleri ve Önceliklendirme

Metrik	Açıklama	Öncelik
Macro F1 Score	Her sınıf için ayrı ayrı hesaplanan F1 skorlarının ağırlıksız ortalaması. Sınıf dengesizliğinden bağımsız olarak her iki sınıftaki başarımı ölçer. Early stopping ve model seçimi bu metriğe göre yapılır.	Birincil
Unsafe F1 (Binary)	Yalnızca unsafe sınıfı için hesaplanan binary F1 skoru. Zararlı içeriği kaçırmanın (FN) yanlış alarm üretmekten (FP) daha maliyetli olduğu varsayımıyla izlenir.	İkincil
Precision & Recall	Safe ve unsafe için ayrı ayrı raporlanır. Unsafe recall (tespit oranı) pratik güvenlik performansının temel göstergesidir.	Destek
Confusion Matrix	Her epoch sonunda hangi sınıfın daha fazla hatalı sınıflandırıldığını ve FP/FN dengesini gösterir.	Tanısal

Metrik Önceliklendirme

Erken durdurma ve model kaydetme kararları macro F1 skoruna göre alınmaktadır. Unsafe F1 ise modelin pratik güvenlik performansını değerlendirmek için ayrıca takip edilmektedir. İki metriğin birbirinden bağımsız değerlendirilmesi, modelin genel dengeli performansını korurken hedef sınıfta (unsafe) da yeterli başarımı sağladığının doğrulanmasını mümkün kılmaktadır.

5.2 Değerlendirme Prosüdürü

Her epoch sonunda model doğrulama setinde değerlendirilmektedir. Değerlendirme sürecinde model tamamen pasif modda çalıştırılmakta, gradient hesaplanmamakta ve ağırlıklar güncellenmemektedir. Bu yaklaşım, doğrulama başarımının eğitim verilerinden bağımsız ve sapmasız biçimde ölçülmesini garantilemektedir. Şekil 5.1 bu süreci adım adım göstermektedir.

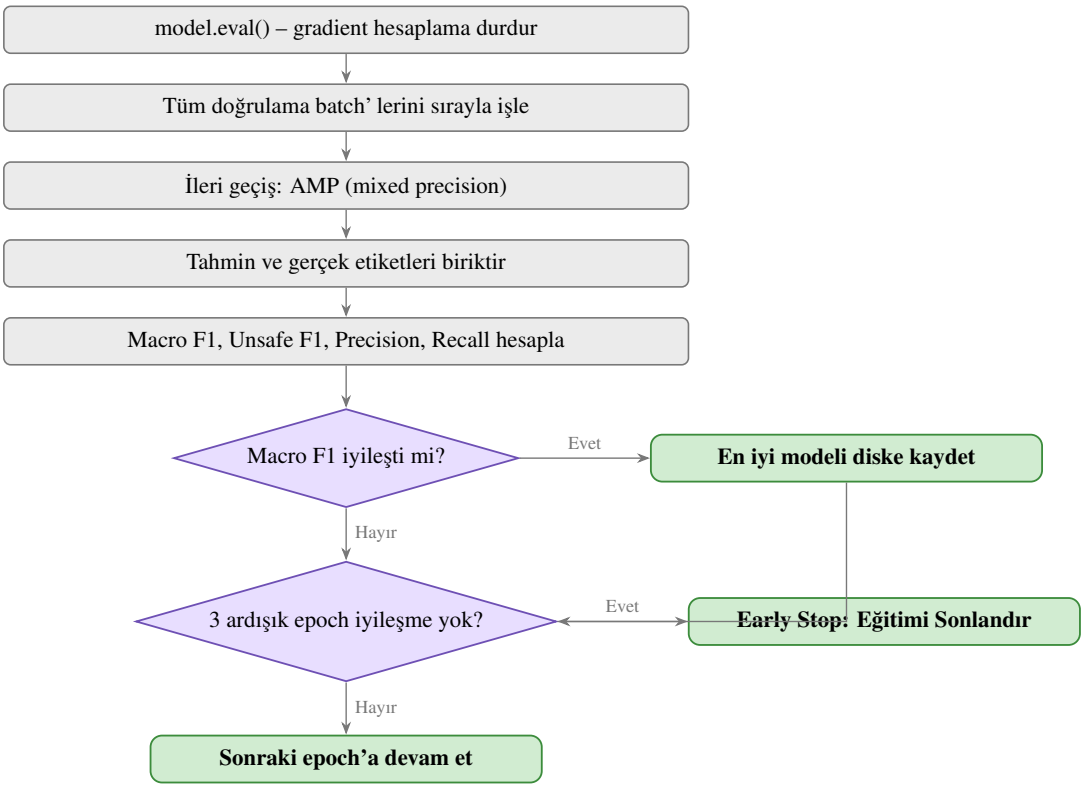

Figure 5.1. Şekil 5.1 – Epoch Bazlı Değerlendirme ve Early Stopping Akış Diyagramı

5.3 Benchmark ile Değerlendirme

Eğitim setinden tamamen bağımsız olan benchmark veri seti, eğitim tamamlandıktan sonra ayrıca uygulanmaktadır. Benchmark, modelin eğitim sürecinde hiç görmediği örneklerden oluşmaktadır ve genel geçerlilikten ziyade belirli zafiyet kategorilerindeki performansı hedefli biçimde ölçmektedir. Tablo 5.2 benchmark bileşenlerini açıklamaktadır.

Table 5.2. Tablo 5.2 – Benchmark Veri Seti Bileşenleri

Bileşen	Açıklama
Prompt Injection Örnekleri	Uzun ve masum görünen bağlamlara gizlenmiş zararlı içerikler; modelin bağlam uzunluğuna karşı dayanıklılığını test eder
Kısa Doğrudan Unsafe	Açık tehdit veya zarar içeren kısa metinler; temel sınıflandırma yetkinliğini ölçer
Türkçe Test Seti	Türkçe unsafe ve safe örnekleri; Türkçe dil kavrayışını ölçer
İngilizce Test Seti	İngilizce unsafe ve safe örnekleri; pretrained bilginin korunduğunu doğrular

Benchmark sonuçları eğitim metrikleriyle karşılaştırıldığında modelin eğitim setini ezberleyip ezberlemediği ya da gerçek anlamda genelleme yapıp yapmadığı gözlemlenebilmektedir. Prompt injection senaryolarındaki başarım ise modelin uzun bağlamda gizlenmiş tehdit tespit kapasitesini ayrı olarak ölçmektedir.

2 Model Eğitim Aşaması

2.1 Denenen Model Mimarisi

Bu çalışmada güvenlik sınıflandırma görevi için Google BigBird (bigbird-roberta-base) modeli temel alınmıştır. BigBird, standart Transformer mimarisinin $O(n^2)$ olan hesaplama karmaşıklığını, Seyrek Dikkat Mekanizması (Sparse Attention: Global + Sliding Window + Random Attention) kullanarak $O(n)$ seviyesine düşürmüştür. Bu optimizasyon, BERT ailesinin standart 512 token limitine karşın 8 kat daha fazla girdi, yani 4096 token'a kadar metin işleme kapasitesi sağlamıştır.

Model seçimindeki temel motivasyon, projenin güvenlik odaklı doğasıdır: Zararlı içeriğin uzun ve zararsız görünen metinlerin içine gizlendiği senaryolar, hedef kullanım durumları arasındadır. 512 token limitli modellerde bu tür gömülü zararlı içerikler kesme nedeniyle kaybolabilirken, BigBird'ün 4096 token kapasitesi bu kritik sorunu doğrudan adreslemiştir.

Eğitim süreci boyunca aynı temel mimari (bigbird-roberta-base) üzerinde 5 farklı eğitim konfigürasyonu (V1–V5) denenmiş, her iterasyonda sistematik analizler ve iyileştirmeler yapılmıştır.

2.2 Model Seçim Kriteri

Nihai model seçiminde temel kriter F1-Skoru metriği olmuştur. Güvenlik sınıflandırma görevlerinde zararlı içeriği kaçırmamak (yüksek Recall/Duyarlılık) ne kadar önemliyse, güvenli içerikleri yanlışlıkla zararlı olarak etiketleyip kullanıcı deneyimini bozmamak da o kadar kritiktir. F1-Skoru, bu iki metriğin harmonik ortalamasını alarak modelin hem tehditleri yakalama gücünü hem de yanlış alarm vermeme kararlılığını en dengeli şekilde yansıttığı için tercih edilmiştir. Bu nedenle tüm versiyonlarda metric_for_best_model="f1" parametresi kullanılmış ve en iyi model ağırlıkları bu kritere göre seçilmiştir. Aday modeller V3 ve V5, en güncel veri seti (v20) ile eğitilmiş ve en son mimari iyileştirmeleri içeren versiyonlardır. Nihai model, bu iki versiyonun test seti performans sonuçlarına göre belirlenecektir.

2.3 Eğitim Süreci ve Versiyon Geliştirmeleri

Eğitim süreci, önceki versiyonlarda tespit edilen darboğazların ve sorunların çözüldüğü iteratif bir yaklaşımla ilerlemiştir. Aşağıda her versiyondaki temel değişiklikler ve bunların gerekçeleri özetlenmiştir.

- **V1 — Temel Yapı (Baseline):**
  - **Konfigürasyon:** BigBird'ün standart ince ayar konfigürasyonu kullanılmıştır. Tüm örnekler sabit olarak 4096 token'a doldurulmuş (padding='max_length'), dikkat mekanizması

block_sparse olarak ayarlanmıştır.

  - **Hiperparametreler:** Batch size 2, gradient accumulation 16 ile efektif batch size 32'ye ulaşılmıştır. Öğrenme oranı 2e-5, epoch sayısı 5, erken durdurma 3'tür. Veri seti augmented_all_v16 kullanılmıştır.
  - **Sorun:** Sabit doldurma nedeniyle eğitim süresi aşırı uzamıştır (yaklaşık 15 saat).

- **V2 — Dinamik Doldurma (Dynamic Padding) ile Hız Optimizasyonu:**
  - **Sorun Çözümü:** V1'deki performans darboğazı, kısa metinlerin gereksiz yere 4096 token'a doldurulmasından kaynaklanmıştır. V2'de bu sorun, batch seviyesinde Dinamik Doldurma yaklaşımıyla çözülmüştür. Her batch'teki en uzun örneğe göre doldurma uygulanmış ve doldurma uzunluğu, BigBird'ün gerektirdiği 64'ün katlarına yuvarlanmıştır.
  - **İyileştirme:** Batch size 2'den 8'e çıkarılmış, gradient accumulation 16'dan 4'e düşürülmüş (efektif batch size 32 korunmuştur) ve eğitim süresi 3-5 kat hızlanmıştır. Dikkat mekanizması block_sparse, veri seti v16'dır.

- **V3 (v3_3) — Dikkat Mekanizması Tutarlılığı:**
  - **Sorun:** V2, harici test setlerinde beklenen performansı gösterememiştir. Analiz, BigBird'ün kısa dizi uzunluklarında otomatik olarak block_sparse yerine original_full dikkat mekanizmasına geçiş yapmasından kaynaklanan tutarsızlığı ortaya çıkarmıştır.
  - **Çözüm:** Dikkat tipi original_full olarak sabitlenmiş ve böylece eğitim ile çıkarım (inference) aşamaları arasındaki tutarlılık sağlanmıştır. Veri seti v20'ye güncellenmiştir.

- **V4 (v3_4) — Erken Durdurma (Early Stopping) Ayarı:**
  - **Sorun:** V3 eğitiminde erken durdurma mekanizması, yeni eklenen veri dağılımları (profanity/slang) nedeniyle oluşan geçici kayıp ve recall düşüşü yüzünden çok erken (epoch 0.61) tetiklenmiştir.
  - **Çözüm:** patience parametresi 3'ten 6'ya, num_epochs 5'ten 7'ye çıkarılmış ve eval steps 500'den 250'ye düşürülerek daha sık değerlendirme yapılmıştır. Veri seti v18'dir.

- **V5 (v3_5) — Erken Durdurmanın Kaldırılması:**
  - **Sorun Çözümü:** Erken durdurmanın yeni veri dağılımlarında güvenilir olmadığı değerlendirilerek, V5'te bu mekanizma tamamen kaldırılmıştır. Sabit 3 epoch eğitim yapılmış, en yüksek recall değerine sahip ağırlıklar otomatik olarak seçilmiştir.

– **Donanım Optimizasyonu:** Paylaşımlı GPU ortamında OOM hatasını önlemek için batch size 8'den 4'e düşürülmüş, gradient_accumulation 4'ten 8'e çıkarılarak efektif batch size 32'de korunmuştur. Değerlendirme stratejisi adım tabanlıdan (step-based) epoch tabanlıya geçirilmiştir. Veri seti v20'dir.

Aşağıdaki tablo, versiyonlar arası temel parametre değişikliklerini özetlemektedir:

Parametre	**V1**	**V2**	**V3 (v3_3)**	**V4 (v3_4)**	**V5 (v3_5)**
Doldurma (Padding)	Sabit 4096	Dinamik	Dinamik	Dinamik	Dinamik
Dikkat Mekanizması (Attention)	block_sparse	block_sparse	original_full	original_full	original_full
Batch Size	2	8	8	8	4
Gradyan Birikimi (Grad. Accum.)	16	4	4	4	8
Efektif Batch Boyutu (Eff. Batch)	32	32	32	32	32
Epoch Sayısı	5	5	5	7	3
Erken Durdurma (Early Stop.)	Patience=3	Patience=3	Patience=3	Patience=6	Yok
Değerlendirme Stratejisi (Eval)	500 step	500 step	500 step	250 step	Epoch
Veri Seti Versiyonu	v16	v16	v20	v18	v20

Tablo 1: Model Versiyonları Arası Temel Parametre Değişiklikleri Özeti

Genel Eğitim Hiperparametreleri

- **learning_rate:** 2e-5
- **warmup_ratio:** 0.1
- **weight_decay:** 0.01
- **UNSAFE_BOOST:** 1.5
- **MAX_LENGTH:** 4096 token
- **FP16:** True
- **gradient_checkpointing:** True

3 Model Değerlendirme Aşaması (BigBird)

3.1 Veri Seti Bölünmesi: Eğitim, Doğrulama ve Test Setleri

Projede kullanılan genişletilmiş veri setinin, modelin eğitim ve değerlendirme aşamalarında kullanılmak üzere bölünmesi, scikit-learn kütüphanesinin train_test_split fonksiyonu ile gerçekleştirilmiştir. Modelin daha önce görmediği veriler üzerindeki performansının objektif ölçümü için aşağıdaki oranlar kullanılmıştır:

- **Test Seti:** Tüm verinin %15'i (TEST_SIZE = 0.15), modelin nihai ve bağımsız başarısını ölçmek için ayrılmıştır.
- **Doğrulama (Validation) Seti:** Geriye kalan eğitim verisinin %10'u (VAL_SIZE = 0.1), eğitim sırasında hiperparametre optimizasyonu ve erken durdurma mekanizmasının takibi için kullanılmıştır.

Veri Kümesi	Oran	Kullanım Amacı
Eğitim (Train)	%76.5	Modelin ağırlıklarının güncellenmesi ve öğrenme süreci.
Doğrulama (Validation)	%8.5	Eğitim sırasındaki metrik takibi ve aşırı öğrenmenin kontrolü.
Test (Test)	%15.0	Eğitim tamamlandıktan sonra nihai ve bağımsız değerlendirme.

Tablo 2: Veri Seti Bölünme Oranları

Bu ayırma işleminde, sınıf dengesizliğinin her alt kümeye (eğitim/doğrulama/test) aynı oranda yansıması için Tabakalı Bölme yöntemi kullanılmıştır. Sonuçların tekrarlanabilirliğini sağlamak amacıyla rastgelelik tohumu (Seed) 42 olarak sabitlenmiştir.

3.2 Değerlendirme Metrikleri

Bir siber güvenlik ve guardrail modelinde, hata tiplerinin maliyeti karşılıklıdır. Güvenli bir içeriğin yanlışlıkla "Güvensiz" olarak etiketlenmesi (False Positive) sistemin kullanılabilirliğini ve kullanıcı deneyimini zedelerken, zararlı bir içeriğin "Güvenli" olarak işaretlenmesi (False Negative) güvenlik açığı yaratır. Bu dengenin sağlanması zorunlu olduğundan, değerlendirmede F1-Skoru merkeze alınmıştır:

- **F1-Score:** Projenin en kritik metriği olup, Kesinlik ve Recall değerlerinin harmonik ortalamasıdır. Hem yanlış alarmları (False Positive) hem de kaçırılan tehditleri (False Negative) dengeli bir şekilde minimize etmeyi hedefler.
- **Kesinlik (Precision):** Modelin "Güvensiz" dediği durumların ne kadarının gerçekten güvensiz olduğunu ölçer. Kullanıcı deneyimini korumak için önemlidir.
- **Duyarlılık (Recall):** Gerçekte "Güvensiz" olan girdilerin yüzde kaçının model tarafından doğru tespit edildiğini gösterir. Sistem güvenliği için kritiktir.
- **Yardımcı Metrikler:** Accuracy, Recall ağırlıklı F2-Score ve sınıflandırma eşiğinden bağımsız başarıyı ölçen AUC-ROC ile AUC-PR metrikleri model davranışını derinlemesine analiz etmek için kullanılmıştır.

3.3 Test ve Tahmin Süreci

Eğitim tamamlandıktan sonra test süreci, modelin daha önce görmediği %15'lik test veri seti üzerinde canlıya en yakın simülasyonla gerçekleştirilmiştir:

- **Olasılık Üretimi (Softmax):** Test verisindeki girdiler modele beslenmiş ve modelin çıktı katmanındaki logit değerleri, PyTorch'un torch.nn.functional.softmax fonksiyonu ile 0-1 arasında olasılık değerlerine dönüştürülmüştür.
- **Sınıf Belirleme (Argmax):** Elde edilen olasılık diziliminde en yüksek değere sahip indeks (np.argmax), tahmin edilen nihai sınıf (0: Güvenli, 1: Güvensiz) olarak atanmıştır.
- **Raporlama:** Modelin tahminleri ile gerçek etiketler karşılaştırılmış ve scikit-learn kütüphanesinin classification report modülü ile detaylı döküm alınmıştır.

Hesaplanan tüm kritik metrikler ve Karmaşıklık Matrisi sonuçları, ileri analizler için test_results.json dosyasına kaydedilerek loglanmıştır.

4 Alınan Sonuçlar ve Sorun Giderme

4.1 Model Çıktıları ve Performans Karşılaştırması

Model değerlendirmesi iki aşamada yapılmıştır:

1. Veri setinin kendi içindeki %15'lik standart test ayrımı (Genel Performans).
2. Özellikle uzun metinlere gizlenmiş "Prompt Injection" saldırılarını tespit etmek üzere hazırlanan, tamamen zararlı içeriklerden oluşan (Unsafe) özel Benchmark Veri Seti.

Aşağıdaki Tablo 2.3'de, modelin versiyon güncellemeleriyle birlikte test veri seti üzerindeki genel performans gelişim seyri görülmektedir:

Versiyon	Genel Doğruluk (Accuracy)	Unsafe Sınıfı Kesinlik (Precision)	Unsafe Sınıfı Duyarlılık (Recall)	Unsafe Sınıfı F1-Skoru
V1	%94.60	%92.25	%97.20	0.9466
V3	%96.38	%95.52	%97.45	0.9647
V4	%97.47	%96.39	%98.35	0.9736
V5	**%98.14**	**%97.96**	**%98.39**	**0.9817**

Tablo 3: Model Versiyonlarına Göre Genel Test Seti Performans Metrikleri

Tablo 2.3'e göre, genel doğruluğun V1'den V5'e doğru %94.60'tan %98.14 seviyesine çıktığı gözlemlenmektedir. Güvenlik modelleri için hayati önem taşıyan "Unsafe Recall" (zararlı olanı yakalama) oranı, V5'te %98.39 seviyesine ulaşarak yüksek bir başarı göstermiştir.

Modelin gizlenmiş tehditlere karşı dayanıklılığını ölçen Benchmark Veri Seti sonuçları Tablo 2.4'te sunulmuştur:

Versiyon	Toplam Test Edilen Tehdit	Doğru Yakalanan (TP)	Kaçırılan Tehdit (FN)	Benchmark Başarı Oranı
V1	188	162	26	%86.17
V3	188	167	21	%88.83
V4	**188**	**175**	**13**	**%93.09**
V5	188	173	15	%92.02

Tablo 4: Özel Benchmark Veri Seti (Sadece Unsafe) Tespit Performansı

4.2 Sonuç Yorumu

Elde edilen sonuçlar beklentileri aşmıştır. Başlangıçta (V1) gizlenmiş tehditlerin 26 tanesi kaçırılırken, veri setinin zenginleştirilmesi ve original_full dikkat mekanizmasına geçilmesiyle bu sayı V5'te 15'e düşürülmüştür. V4, spesifik benchmark testinde ufak bir farkla daha az tehdit kaçırmış olsa da (%93.09), V5 modeli test veri setinde sunduğu 0.9817'lik F1-Skoru sayesinde, yanlış alarmlar ile kaçırılan tehditler arasında en optimum dengeyi kuran ve aşırı öğrenme yapmayan nihai model olarak seçilmiştir.

3 Projede Kullanılan Teknolojiler

Bu bölüm, güvenlik sınıflandırma ve veri çevirisi süreçlerinin geliştirilmesi, eğitilmesi ve canlı API ortamında sunulması aşamalarında kullanılan teknoloji yığınını özetlemektedir. Proje, üç kişilik bir mühendislik ekibinin asenkron çalışabilmesini destekleyen modüler bir mimariyle inşa edilmiştir.

3.1 Programlama Dilleri

Projenin tüm modüllerinde ana dil olarak Python tercih edilmiştir. Modüllerin gereksinimlerine göre farklı versiyonlar kullanılmıştır:

- **Python 3.10+:** Gerçek zamanlı güvenlik sınıflandırması model çıkarımı ve derin öğrenme model eğitimleri için kullanılmıştır.
- **Python 3.12:** vLLM API orkestrasyonu, paralel veri çevirisi ve deneysel model testleri için kullanılmıştır.

3.2 Kütüphaneler ve Framework'ler

Framework / Araç	Versiyon	Kullanım Alanı
PyTorch	2.0+	Model yükleme, tensör işlemleri, GPU optimizasyonu.
Transformers (Hugging Face)	4.30+	Önceden eğitilmiş modeller, Trainer API, tokenizasyon.
BigBird	-	4096 token desteği ile uzun prompt (metin) işleme.
ModernBERT	-	Modern transformer mimarisi ile güvenlik sınıflandırması (deney).
Longformer	-	4096 token (4x genişletme) ile uzun doküman sınıflandırması (deney).
XLM-RoBERTa	-	100+ dil desteği, Sliding Window ile sınırsız uzunluk işleme (deney).
BERT Turkish	-	dbmdz/bert-base üzerinden Türkçe spesifik sınıflandırma (512 token) (deney).
Datasets (Hugging Face)	2.14+	Veri seti yönetimi, ön işleme, HF Hub entegrasyonu.
Evaluate (Hugging Face)	0.4+	Accuracy, F1-score, ROC-AUC gibi metriklerin hesabı.
scikit-learn	1.3+	train_test_split, karmaşıklık matrisi ve sınıflandırma raporlarının oluşturulması.

Tablo 1: Derin Öğrenme ve Makine Öğrenmesi Kütüphaneleri ve Kullanım Alanları

Veri İşleme, Görselleştirme ve Ağ İletişimi

- **Veri İşleme:** pandas (DataFrame analizleri), numpy (sayısal hesaplamalar), pyarrow (veri serileştirme).
- **API ve Ağ:** requests (Senkron HTTP POST işlemleri), aiohttp (Asenkron paralel API istekleri).
- **Görsel İşleme:** PIL/Pillow (Görüntü tabanlı sınıflandırma ön işlemleri).

Paralelizasyon ve Eşzamanlılık (Multi-tasking)

Ağ darboğazlarını ve eğitim sürelerini optimize etmek için çoklu görev araçları kullanılmıştır:

- **concurrent.futures & threading:** Paralel API istekleri ve batch işleme.
- **asyncio:** vLLM API'sine yönelik asenkron çağrılar.

- **vLLM:** Yüksek verimli paralel LLM çıkarım (inference) sunucusu.
- **Multi-GPU Support:** BigBird eğitiminde donanım optimizasyonu.

Yardımcı Araçlar (Utilities)

- **Konfigürasyon:** python-dotenv (.env yönetimi), pyyaml (YAML konfigürasyonları).
- **İşlem Takibi & Loglama:** logging (detaylı hata takibi), tqdm (eğitim/çıkarım ilerleme çubukları).
- **Veri & Model Güvenliği:** safetensors (güvenli model serileştirme), langdetect (otomatik dil tespiti).

3.3 Geliştirme Ortamları ve Araçlar

- **IDE & Geliştirme:** Jupyter Notebook (etkileşimli analiz), Visual Studio Code (geliştirme, hata ayıklama, Git entegrasyonu), Python REPL/Scriptleri.
- **Paket Yönetimi:** Python venv (sanal ortam izolasyonu), pip, requirements.txt ve pyproject.toml.
- **Model Kayıt ve İzleme:** HuggingFace Model Hub (önceden eğitilmiş modeller), .pt/.bin/.safetensors formatlarında yerel ağırlık kayıtları (checkpointing), stdout yönlendirmeli nohup log dosyaları.
- **Veri Yönetimi:** JSON/JSONL formatında temel veri depolama ve HuggingFace Datasets tabanlı versiyon kontrolü.

1 Model Eğitimi

1.1 Model Seçimi

Bu çalışmada guardrail sınıflandırma modeli olarak ModernBERT-base (`https://huggingface.co/answerdotai/ModernBERT-base`) mimarisi kullanılmıştır. ModernBERT, klasik BERT mimarisinin güncel Transformer optimizasyonları ile geliştirilmiş encoder-only bir modeldir. Model özellikle uzun bağlamları işleyebilme yeteneği nedeniyle tercih edilmiştir.

Guardrail sistemlerinde kullanıcı promptları, özellikle jailbreak ve prompt injection girişimlerinde, oldukça uzun olabilmektedir. ModernBERT mimarisi 8192 token uzunluğa kadar giriş işleyebildiği için uzun metinler içerisinde yer alan zararlı içeriklerin tespiti mümkün olmaktadır. Ayrıca encoder-only yapısı sayesinde generatif modellere kıyasla daha düşük gecikmeli çıkarım sağlanmaktadır.

1.2 Eğitim Altyapısı

Model eğitimi yüksek performanslı bir GPU sunucusunda gerçekleştirilmiştir. Eğitim altyapısında 8 adet NVIDIA H200 GPU bulunmaktadır. Her bir GPU yaklaşık 140 GB belleğe sahip olup sistemde toplam yaklaşık 1,12 TB GPU belleği mevcuttur.

Eğitim sürecinde tek bir GPU kullanılmıştır. H200 GPU'nun yüksek bellek kapasitesi sayesinde 8192 token uzunluğundaki giriş dizileri ile model eğitimi sorunsuz şekilde gerçekleştirilmiştir.

1.3 Eğitim Yaklaşımı

Model eğitimi denetimli öğrenme (supervised learning) yöntemi ile gerçekleştirilmiştir. Problem, kullanıcı promptlarının safe veya unsafe olarak sınıflandırıldığı ikili metin sınıflandırma görevi olarak ele alınmıştır. Veri seti JSON formatında saklanmakta olup her örnek bir prompt metni ve buna karşılık gelen güvenlik etiketi içermektedir. Safe içerikler 0, unsafe içerikler ise 1 etiketi ile temsil edilmektedir. ModernBERT modeli sequence classification başlığı ile birlikte kullanılmış ve tüm model parametreleri güncellenerek full fine-tuning uygulanmıştır.

1.4 Eğitim Hiperparametreleri

Model eğitiminde kullanılan temel hiperparametreler aşağıda özetlenmiştir. Maksimum giriş uzunluğu 8192 token, toplam eğitim süresi 3 epoch olarak belirlenmiştir. GPU bellek kullanımını dengelemek amacıyla fiziksel batch size 4 olarak seçilmiş; gradient accumulation (8 adım) uygulanarak etkili batch size değeri 32'ye yükseltilmiştir. Optimizasyon için AdamW kullanılmış, öğrenme oranı yaklaşık `1e-5` olarak ayarlanmıştır. Öğrenme oranı planlaması için linear warmup scheduler tercih edilmiş ve warmup oranı toplam adımların %10'u olarak belirlenmiştir. Veri seti rastgele karıştırıldıktan sonra %90 eğitim

ve %10 test olacak şekilde bölünmüştür.

1.5 Eğitim Pipeline'ı

Eğitim pipeline'ı veri yükleme, tokenizasyon, batch oluşturma ve model güncelleme aşamalarından oluşmaktadır. Veri seti JSON formatında yüklenmekte ve rastgele karıştırılarak eğitim/test kümelerine ayrılmaktadır. Prompt metinleri ModernBERT tokenizer kullanılarak tokenize edilmekte, maksimum uzunluk 8192 token ile sınırlandırılmaktadır.

Padding işlemi tokenizer aşamasında değil, batch seviyesinde dinamik olarak uygulanmıştır. Bu yaklaşım her batch için yalnızca gerekli uzunluk kadar padding kullanılmasını sağlayarak GPU belleğinin daha verimli kullanımına katkıda bulunmaktadır. Eğitim sürecinde FP16 ve FP32 hassasiyetlerinin birlikte kullanıldığı automatic mixed precision (AMP) etkinleştirilmiş; bu sayede hem eğitim hızı artırılmış hem de bellek tüketimi azaltılmıştır. Model birden fazla kez farklı veri ve parametre kombinasyonlarıyla eğitilmiş; en yüksek doğrulama başarısını veren checkpoint nihai model olarak seçilmiştir.

2 Modelin Değerlendirme Aşaması

2.1 Eğitim Sonuçları

Model toplam 3 epoch boyunca eğitilmiş ve her epoch sonunda doğrulama seti üzerinde performans değerlendirmesi yapılmıştır. Eğitim süreci boyunca kayıp (loss) değerinin istikrarlı biçimde azaldığı, doğruluk (accuracy) değerinin ise sürekli artış eğiliminde olduğu gözlemlenmiştir. Bu durum modelin sınıflandırma görevini giderek daha iyi öğrendiğini ve optimizasyon sürecinin kararlı şekilde ilerlediğini göstermektedir.

Epoch bazlı sonuçlar Tablo 1'da, epoch 2'den epoch 3'e geçişte yaşanan metrik değişimleri ise Tablo 2'de özetlenmiştir. Son epoch'ta modelin daha düşük kayıpla benzer doğruluk seviyesini koruyarak genelleme kapasitesini artırdığı görülmektedir. Eğitim sonunda en yüksek doğrulama doğruluğunu veren checkpoint otomatik olarak kaydedilmiş ve değerlendirme aşamasında bu model kullanılmıştır. Eğitim sürecine ait kayıp ve doğruluk eğrileri Şekil 1'te sunulmaktadır.

Tablo 1: Epoch bazlı eğitim performansı. Her epoch sonunda doğrulama setinde hesaplanan ortalama kayıp ve doğruluk değerleri görülmektedir.

Epoch	Ortalama Loss	Accuracy	Hata Oranı
2	0.0438	0.9849 (%98.49)	%1.51
3	0.0185	0.9863 (%98.63)	%1.37

Tablo 2: Epoch 2'den Epoch 3'e geçişte gözlemlenen metrik değişimleri. Loss değerinde yaklaşık %57.8 oranında belirgin bir düşüş yaşanmıştır.

Metrik	**Değişim**
Loss değişimi	−0.0253 (yaklaşık %57.8 azalma)
Accuracy değişimi	+0.0014 (yaklaşık +0.14 puan)
Hata oranı değişimi	%1.51 → %1.37 (yaklaşık %9.3 göreli azalma)

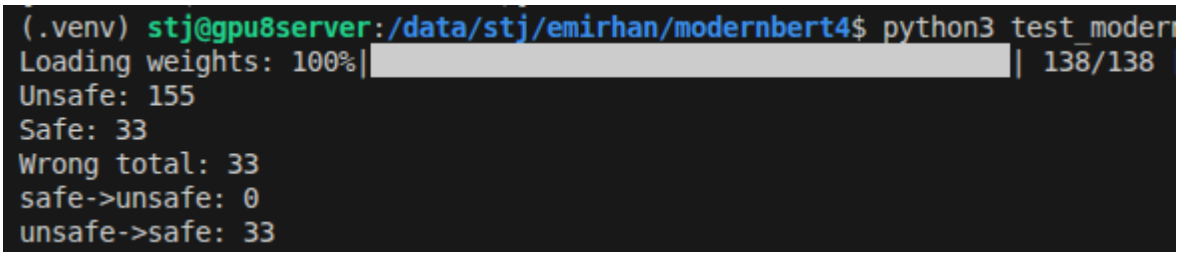

Şekil 1: ModernBERT-base modelinin eğitim sürecine ait kayıp (loss) ve doğruluk (accuracy) eğrileri. Epoch ilerledikçe kayıp değerinin azaldığı ve doğruluk değerinin arttığı görülmektedir.

2.2 Modelin Çoklu Yöntemle Değerlendirilmesi

Model performansı yalnızca eğitim sürecindeki doğrulama sonuçları ile sınırlı tutulmamış; gerçek kullanım koşullarını daha iyi temsil etmek için iki farklı değerlendirme yöntemi uygulanmıştır: (1) chatbot arayüzü üzerinden manuel değerlendirme ve (2) bağımsız benchmark veri seti üzerinde otomatik değerlendirme. Bu yaklaşım sayesinde hem kontrollü test metrikleri hem de kullanıcı etkileşimine yakın senaryolardaki model davranışı birlikte analiz edilmiştir.

2.2.1 Chatbot ile Manuel Değerlendirme

Eğitilen model, gerçek kullanıcı etkileşimlerini simüle eden chatbot arayüzünde manuel olarak test edilmiştir. Bu aşamada farklı risk düzeylerine sahip prompt türleri – açık zararlı talepler, sınırda/örtük talepler ve açıkça güvenli talepler – ile modelin karar tutarlılığı gözlemlenmiştir. Manuel testlerin temel katkısı, modelin yalnızca veri setindeki örneklere değil, doğal dildeki farklı ifade biçimlerine nasıl tepki verdiğini incelemektir. Özellikle yeniden ifade edilmiş zararlı taleplerde modelin duyarlılığı ve güvenli içeriklerde yanlış alarm üretme eğilimi bu aşamada kontrol edilmiştir.

2.2.2 Benchmark Test Seti ile Değerlendirme

Model, `benchmark_basit_veri_lower.json` adlı bağımsız test seti üzerinde `test_modernbert4.py` betiği ile sistematik biçimde değerlendirilmiştir. Test setine ait sınıf dağılımı Tablo 3'da, genel performans sonuçları ise Tablo 4'ta verilmektedir.

Toplam 188 örnekten oluşan test setinde sınıf dağılımı dengesizdir ve unsafe örnekler büyük çoğunluğu oluşturmaktadır. Benchmark sonuçları (bkz. Şekil 2) modelin, üretim senaryosuna yakın bu bağımsız veri setinde temel başarı kriteri olan %80 accuracy eşiğini aştığını ortaya koymaktadır. Bununla birlikte, hata örnekleri incelendiğinde bazı zararlı içeriklerin kaçırıldığı (false negative riski) anlaşılmaktadır. Bu nedenle bir sonraki aşamada eşik optimizasyonu, sınıf ağırlığı ayarı ve zor örneklerle ek fine-tuning uygulanarak unsafe sınıfı için recall artışı hedeflenmelidir.

Tablo 3: Benchmark test setindeki sınıf dağılımı. Unsafe örneklerin oranı %82.45 ile çoğunluğu oluşturmaktadır; bu dengesizlik değerlendirme metriklerinin yorumlanmasında dikkate alınmalıdır.

Sınıf	**Örnek Sayısı**	**Oran**
unsafe	155	%82.45
safe	33	%17.55
Toplam	**188**	**%100**

Tablo 4: Benchmark test seti genel sonuçları. Model, %80 başarı kriterini aşarak %82.45 accuracy elde etmiştir. Yanlış tahminlerin tamamına yakını false negative niteliği taşımaktadır.

Metrik	**Değer**
Toplam örnek sayısı	188
Doğru tahmin sayısı (yaklaşık)	155
Yanlış tahmin sayısı (yaklaşık)	33
Genel başarı (accuracy)	**%82.45**

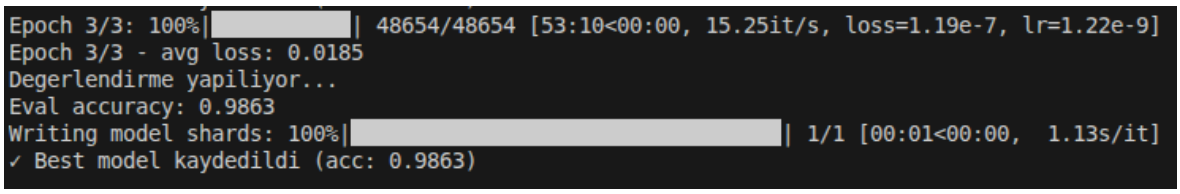

Şekil 2: Benchmark test seti üzerindeki model performansı. Confusion matrix ve sınıf bazlı metrikler (precision, recall, F1) görülmektedir. Unsafe sınıfına ait recall değerinin iyileştirilmesi öncelikli hedef olarak öne çıkmaktadır.

2.3 Genel Değerlendirme

Eğitim sürecinde elde edilen %98.63 doğruluk ile bağımsız benchmark üzerindeki %82.45 doğruluk birlikte değerlendirildiğinde, modelin güçlü bir temel performans sunduğu görülmektedir. Eğitim/doğrulama sonuçlarının benchmark testine kıyasla yüksek kalması, modelin kontrollü veri dağılımında daha başarılı olduğunu; gerçek dünya çeşitliliğinde ise ilave iyileştirmelere ihtiyaç duyduğunu

göstermektedir. Buna karşın model, guardrail katmanı olarak üretim öncesi filtreleme için kullanılabilir bir olgunluk seviyesine ulaşmıştır.

2.4 Hata Analizi ve Veri Seti Güncelleme

Modelin yanlış sınıflandırdığı örnekler detaylı biçimde incelenerek hata analizi yapılmıştır. Bu analiz sayesinde modelin hangi tür içerikleri kaçırdığı belirlenmiş ve yanlış tahminlerin ortak özellikleri ortaya konmuştur. Elde edilen bulgular doğrultusunda veri setinde eksik temsil edilen örüntüler tespit edilerek veri seti güncellenmiştir. Bu süreç, modelin zayıf kaldığı içerik türlerini daha iyi öğrenebilmesi amacıyla iteratif biçimde yürütülmüştür.

2.5 Karşılaşılan Sorunlar ve Çözümler

Geliştirme sürecinde dört temel problem tespit edilmiş ve her biri için çözüm üretilmiştir:

- **Anlamsız Girdi Sınıflandırması:** Yalnızca rakam veya harflerden oluşan kısa girdilerin bazı durumlarda unsafe olarak sınıflandırıldığı gözlemlenmiştir. Bu tür nötr örneklerin eğitim veri setinde yeterince temsil edilmediği anlaşılmış; sayılar, kısa karakter dizileri ve anlamsız metinlerden oluşan ek örnekler safe etiketi ile veri setine eklenerek model yeniden eğitilmiştir.
- **Dil Dengesizliği:** Türkçe ve İngilizce veri dağılımındaki dengesizlik, modelin farklı dillerde tutarsız sınıflandırma davranışı sergilemesine yol açmıştır. LLM tabanlı otomatik çeviri yöntemiyle veri seti iki dil arasında dengeli hale getirilmiştir.
- **Veri Sürüm Karışıklığı:** Büyük ölçekli veri setleriyle çalışırken sürüm takibinin zorlaşması problemi ortaya çıkmıştır. Her güncellemenin izlenebilir ve tekrarlanabilir olması amacıyla veri seti versiyonlama yaklaşımı benimsenmiştir.
- **Yanlış Etiket (Label Noise):** Veri setindeki bazı örneklerin hatalı etiketlendiği tespit edilmiştir. vLLM üzerinden çalışan bir LLM modeli ile otomatik kalite kontrol süreci uygulanmış; şüpheli etiketler manuel incelemeyle düzeltilmiştir.

Bu süreç boyunca benchmark testleri, chatbot üzerinden yapılan manuel testler ve hata analizleri birlikte değerlendirilmiş; elde edilen bulgular doğrultusunda veri seti ve model iteratif olarak iyileştirilmiştir. Böylece modelin gerçek kullanım senaryolarındaki güvenilirliği artırılmıştır.

4 Sonuç

4.1 Genel Değerlendirme

Bu proje kapsamında, HAVELSAN bünyesinde geliştirilen MAİN büyük dil modeli için Türkçe ve İngilizce dillerinde yüksek performans gösteren, güvenilir ve özelleştirilebilir bir guardrail sistemi başarıyla geliştirilmiştir. Projenin başlangıcında belirlenen temel hedef olan "minimum %80 doğruluk (accuracy) oranına ulaşma" kriteri fazlasıyla aşılmıştır. Model eğitim aşamalarında detaylandırıldığı üzere; optimize edilen BigBird V5 modeli standart test veri setinde %98.14 doğruluğa ulaşırken, ModernBERT mimarisi %98.63 doğruluk elde ederek her iki mimaride de %98'in üzerinde bir başarım sergilemiştir.

Mevcut açık kaynaklı çözümlerin Türkçe dilindeki yetersizlikleri, projeye özel tasarlanan titiz bir veri hazırlama pipeline ile giderilmiştir. Çeşitli açık kaynaklı veri setlerinin anlam kayması yaşanmadan Türkçeye çevrilmesi, Qwen tabanlı kalite kontrol filtrelemesi ve vLLM destekli sentetik veri üretimi, modelin öğrenme uzayını son derece zenginleştirmiştir.

Model mimarisi tarafında ise 512 token limiti aşılmış; BigBird (4096 token) ve ModernBERT (8192 token) gibi uzun bağlam işleyebilen mimariler kullanılarak, gerçek dünya senaryolarında en büyük tehditlerden biri olan uzun metinlere gizlenmiş "Prompt Injection" saldırılarına karşı yüksek bir direnç elde edilmiştir. Bu direnç, özellikle sadece zararlı (unsafe) içeriklerin uzun bağlamlara gizlenmesiyle oluşturulan "Benchmark Veri Seti" testlerinde kanıtlanmıştır. Tablo 2.4'te de görüldüğü üzere, BigBird V4 modeli %93.09, V5 modeli ise %92.02 Benchmark başarı oranına ulaşarak False Negative sayılarını sıfıra yaklaştırmıştır.

Elde edilen bu sonuçlar, geliştirilen yerli çözümün kurumsal düzeyde bir LLM entegrasyonu için üretime hazır, stabil ve yüksek güvenilirlikli olduğunu kanıtlamaktadır.

4.2 Gelecek Çalışmalar

Proje mevcut haliyle temel başarı kriterlerini fazlasıyla karşılamış olsa da, guardrail sisteminin sürekli gelişen LLM tehditlerine karşı güncel tutulması ve performansının daha da artırılması için aşağıdaki adımlar gelecek çalışmalar olarak planlanmaktadır:

- **Sürekli Öğrenme ve Aktif Veri Toplama:** Model canlı ortama alındıktan sonra, kullanıcıların MAİN LLM ile olan gerçek etkileşimlerinden elde edilecek verilerle bir geri bildirim döngüsü (RLHF veya DPO) kurulması hedeflenmektedir. Canlı sistemdeki yoğun istek trafiğini kesintisiz ve hatasız yönetebilmek adına sisteme Load Balancer mimarisi entegre edilecektir. Bu sayede modelin zamanla ortaya çıkabilecek yeni "Jailbreak" taktiklerine karşı darboğaz yaşanmadan, asenkron ve dinamik olarak eğitilmesi sağlanacaktır.

- **Çıkarım Hızlandırma ve Optimizasyon:** Gerçek zamanlı sistemlerdeki gecikmeyi (latency) minimuma indirmek amacıyla, elde edilen nihai model ağırlıklarının Quantization (Örn: INT8, AWQ) veya TensorRT gibi yöntemlerle optimize edilmesi planlanmaktadır. Buna ek olarak, modelin donanım kısıtlamalarından bağımsız, en yüksek hızda ve esneklikte çalışabilmesi için ONNX (Open Neural Network Exchange) formatına dönüştürülmesi ve çıkarım süreçlerinin ONNX Runtime üzerinden sunulması hedeflenmektedir. Bu geliştirmelerle GPU kaynak kullanımının daha da verimli hale getirilmesi sağlanacaktır.

- **Çok Sınıflı Sınıflandırma ve Detaylı Analitik:** Mevcut ikili (Safe/Unsafe) sınıflandırma yapısının, tehdit türlerine göre (Örn: Siber Saldırı, Nefret Söylemi, Dezenformasyon vb.) çok sınıflı bir yapıya genişletilmesi. Bu geliştirme, güvenlik ihlallerinin türüne göre farklı aksiyonların veya özel hata mesajlarının tetiklenmesine olanak tanıyacaktır.

Bibliography

[1] Salesforce, "wikitext dataset." [Online]. Available: https://huggingface.co/datasets/Salesforce/wikitext

[2] OpenAssistant, "oasst1 dataset." [Online]. Available: https://huggingface.co/datasets/OpenAssistant/oasst1

[3] erythropygia, "Thinkingdata-200k-turkish dataset." [Online]. Available: https://huggingface.co/datasets/erythropygia/ThinkingData-200K-Turkish

[4] IBM, "Attaq dataset." [Online]. Available: https://huggingface.co/datasets/ibm/AttaQ

[5] Babelscape, "Alert dataset." [Online]. Available: https://huggingface.co/datasets/Babelscape/ALERT

[6] walledai, "Saladbench dataset." [Online]. Available: https://huggingface.co/datasets/walledai/SaladBench

[7] Bertie Vidgen, "Simplesafetytests dataset." [Online]. Available: https://huggingface.co/datasets/Bertievidgen/SimpleSafetyTests

[8] Center for AI Safety, "Harmbench." [Online]. Available: https://github.com/centerforaisafety/HarmBench

[9] Alexandra Souly et al., "Strongreject." [Online]. Available: https://github.com/alexandrasouly/strongreject

[10] walledai, "Advbench dataset." [Online]. Available: https://huggingface.co/datasets/walledai/AdvBench

[11] CysecBench, "Cysecbench dataset repository." [Online]. Available: https://github.com/cysecbench/dataset

[12] Anthropic, "hh-rlhf dataset." [Online]. Available: https://huggingface.co/datasets/Anthropic/hh-rlhf

[13] LibrAI, "do-not-answer dataset." [Online]. Available: https://huggingface.co/datasets/LibrAI/do-not-answer

[14] NVIDIA, "Aegis ai content safety dataset 2.0." [Online]. Available: https://huggingface.co/datasets/nvidia/Aegis-AI-Content-Safety-Dataset-2.0

[15] OpenBMB, "Ultrasafety dataset." [Online]. Available: https://huggingface.co/datasets/OpenBMB/UltraSafety

[16] xTRam1, "safe-guard-prompt-injection dataset." [Online]. Available: https://huggingface.co/datasets/xTRam1/safe-guard-prompt-injection

[17] gabrielchua, "system-prompt-leakage dataset." [Online]. Available: https://huggingface.co/datasets/gabrielchua/system-prompt-leakage

[18] Meta AI, "cyberseceval3-visual-prompt-injection dataset." [Online]. Available: https://huggingface.co/datasets/facebook/cyberseceval3-visual-prompt-injection

[19] Allen Institute for AI, "scrapinghub-article-extraction-benchmark dataset." [Online]. Available: https://huggingface.co/datasets/allenai/scrapinghub-article-extraction-benchmark

[20] deepset, "prompt-injections dataset." [Online]. Available: https://huggingface.co/datasets/deepset/prompt-injections

[21] ai4privacy, "pii-masking-200k dataset." [Online]. Available: https://huggingface.co/datasets/ai4privacy/pii-masking-200k

[22] Allen Institute for AI, "real-toxicity-prompts dataset." [Online]. Available: https://huggingface.co/datasets/allenai/real-toxicity-prompts

[23] ToxiGen, "toxigen-data dataset." [Online]. Available: https://huggingface.co/datasets/toxigen/toxigen-data

[24] kadirnar, "combined-turkish-datasets-v5 dataset." [Online]. Available: https://huggingface.co/datasets/kadirnar/combined-turkish-datasets-v5

[25] Helsinki-NLP, "Helsinki-nlp model hub." [Online]. Available: https://huggingface.co/Helsinki-NLP

[26] QwenLM, "Qwen2.5 repository." [Online]. Available: https://github.com/QwenLM/Qwen2.5

[27] Allen Institute for AI, "longformer-base-4096 model card." [Online]. Available: https://huggingface.co/allenai/longformer-base-4096

[28] markussagen, "xlm-roberta-longformer-base-4096 model card." [Online]. Available: https://huggingface.co/markussagen/xlm-roberta-longformer-base-4096

[29] ytu-ce-cosmos, "turkish-base-bert-uncased model card." [Online]. Available: https://huggingface.co/ytu-ce-cosmos/turkish-base-bert-uncased

[30] emrecan, "bert-base-turkish-cased-mean-nli-stsb-tr model card." [Online]. Available: https://huggingface.co/emrecan/bert-base-turkish-cased-mean-nli-stsb-tr

[31] Jina AI, "jina-reranker-v2-base-multilingual model card." [Online]. Available: https://huggingface.co/jinaai/jina-reranker-v2-base-multilingual

[32] Alibaba-NLP, "gte-multilingual-mlm-base model card." [Online]. Available: https://huggingface.co/Alibaba-NLP/gte-multilingual-mlm-base

[33] JHU CLSP, "mmbert-base model card." [Online]. Available: https://huggingface.co/jhu-clsp/mmBERT-base

[34] I. Beltagy, M. E. Peters, and A. Cohan, "Longformer: The long-document transformer," *arXiv preprint arXiv:2004.05150*, 2020. [Online]. Available: https://arxiv.org/abs/2004.05150

[35] T.-Y. Lin, P. Goyal, R. Girshick, K. He, and P. Dollár, "Focal loss for dense object detection," *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, 2017. [Online]. Available: https://arxiv.org/abs/1708.02002

[36] PyTorch Contributors, "Pytorch." [Online]. Available: https://pytorch.org

[37] Hugging Face, "Transformers documentation." [Online]. Available: https://huggingface.co/docs/transformers

[38] M. Zaheer, G. Guruganesh, A. Dubey, J. Ainslie, C. Alberti, S. Ontañón, P. Pham, A. Ravula, Q. Wang, L. Yang, and A. Ahmed, "Big bird: Transformers for longer sequences," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 33, 2020, pp. 17 283–17 297.